

مبانی و الگوریتم‌های کلان‌داده

جزوه جامع درسی و مرجع دانشگاهی تحلیل کلان‌داده

بر اساس سرفصل‌ها و اسلایدهای کتاب (MMDS) Datasets Massive of Mining
تألیف: ژوره لسکوک، آناند راجارامان، جفری اولمن

گردآورنده: احسان شهبازی

مجموعه یادداشتهای آموزشی کارشناسی ارشد

۷ مهر ۱۴۰۵

فصل ۱

داده‌کاوی و فضاهای با بعد بالا

۱.۱ مقدمه و تعاریف پایه

در دنیای مدرن، سازمان‌ها، موتورهای جستجو، شبکه‌های اجتماعی و سامانه‌های علمی با حجم عظیمی از داده‌های دیجیتال روبرو هستند. گردآوری و ذخیره‌سازی داده‌ها گام نخست است، اما ارزش واقعی داده‌ها زمانی پدیدار می‌شود که بتوان از آن‌ها ^۱ دانش و بینش عملیاتی استخراج نمود. رشته علمی و مهندسی که به این مقصود اختصاص دارد، **داده‌کاوی** ^۲ نامیده می‌شود.

تعریف ۱.۱: داده‌کاوی

داده‌کاوی به فرآیند کشف خودکار یا نیمه‌خودکار الگوها، مدل‌ها و همبستگی‌های پنهان در مجموعه داده‌های عظیم اطلاق می‌شود، به گونه‌ای که الگوهای به‌دست‌آمده دارای ویژگی‌های زیر باشند:

۱. **معتبر بودن**^a: بر روی داده‌های جدید نیز با درجه اطمینان مشخصی صادق باشد (پرهیز از بیش‌برازش).
۲. **سودمند بودن**^b: بتوان بر مبنای آن تصمیمی عملیاتی یا تجاری اتخاذ کرد.
۳. **غیربدیهی و غیرمنتظره بودن**^c: صرفاً تکرار بدیهیات و روابط از پیش شناخته‌شده نباشد.
۴. **قابل فهم بودن برای انسان**^d: ساختار کشف‌شده توسط تحلیل‌گران قابل تفسیر باشد.

Valid^a
Useful^b
Unexpected^c
Understandable^d


از منظر اهداف تحلیلی، روش‌های داده‌کاوی غالباً به دو دسته بزرگ تقسیم می‌شوند:

- **روش‌های توصیفی**^۳: یافتن الگوهای ساختاری که داده‌های موجود را به شیوه‌ای قابل درک برای انسان توصیف و دسته‌بندی می‌کنند. شاخص‌ترین نمونه این روش‌ها، **خوشه‌بندی**^۴ و **کاوش قوانین انجمنی**^۵ است.
- **روش‌های پیش‌بینانه**^۶: استفاده از متغیرهای معلوم برای پیش‌بینی مقادیر مجهول یا رخداد‌های آینده. نمونه‌های بارز آن شامل الگوریتم‌های **طبقه‌بندی**^۷، **رگرسیون**^۸ و **سامانه‌های توصیه‌گر**^۹ است.

Knowledge^۱
Data Mining^۲
Descriptive Methods^۳
Clustering^۴
Association Rules^۵
Predictive Methods^۶
Classification^۷
Regression^۸
Recommender Systems^۹

۲.۱ داده‌کاوی در تقاطع پایگاه‌های داده، یادگیری ماشین و نظریه الگوریتم‌ها

داده‌کاوی رشته‌ای مجزا و در عین حال پیونددهنده میان چند حوزه کلاسیک در علوم کامپیوتر است (شکل ۱.۱):



شکل ۱.۱: جایگاه داده‌کاوی در تقاطع پایگاه داده، یادگیری ماشین و نظریه الگوریتم‌ها

تفاوت فرهنگ‌های علمی در این زمینه‌ها شایان توجه است:

۱. دیدگاه پایگاه داده^{۱۰}: در این دیدگاه، داده‌کاوی به مثابه یک پردازش تحلیلی در مقیاس بسیار وسیع (OLAP) تلقی می‌شود؛ هدف، اجرای بهینه پرس‌وجوهایی است که میلیون‌ها رکورد را غربال می‌کنند و خروجی نهایی، پاسخ صریح همان پرس‌وجو است.
۲. دیدگاه یادگیری ماشین^{۱۱}: در این فرهنگ، هدف استنتاج یک مدل ریاضی و تخمین پارامترهای آن مدل است. خروجی نهایی، بردار وزن‌ها، درخت تصمیم یا ساختار شبکه عصبی است.
۳. دیدگاه کلان‌داده (MMDS)^{۱۲}: در درس کلان‌داده، ما هر دو دیدگاه را ادغام می‌کنیم، اما تأکید اصلی بر مقیاس‌پذیری^{۱۳}، معماری‌های محاسباتی^{۱۴} (نظیر پردازش موازی و جریانی) و پیچیدگی محاسباتی است.

۳.۱ محدودیت‌های آماری در داده‌کاوی و اصل بونفرونی

یکی از بزرگ‌ترین خطرات در کاوش کلان‌داده‌ها این است که تحلیل‌گر با جستجو در میان انبوهی از متغیرها، الگوهایی را کشف کند که کاملاً تصادفی و ساختگی هستند، اما از نظر ظاهری بسیار مهم جلوه می‌کنند. این چالش در علم آمار تحت عنوان اصل بونفرونی^{۱۴} شناخته می‌شود.

قضیه ۱.۱: اصل بونفرونی

اگر شما برای یافتن الگوهای جالب، فضایی بسیار بزرگ‌تر از آنچه که اندازه داده‌هایتان می‌تواند پشتیبانی کند را جستجو نمایید، با قطعیت ریاضی الگوهایی پیدا خواهید کرد که صرفاً حاصل تصادف هستند و هیچ رابطه علت و معلولی یا اعتبار تجربی در جهان واقعیت ندارند.

به بیان دقیق‌تر، اگر یک فرضیه وجود داشته باشد و احتمال رخداد تصادفی آن در یک آزمایش p باشد، چنانچه N آزمایش مستقل انجام دهیم، امید ریاضی تعداد دفعاتی که این فرضیه به طور تصادفی ارضا می‌شود برابر است با:

$$E = N \times p \quad (1.1)$$

اگر $1 \ll N \times p$ باشد، مشاهده چنین الگویی نباید دلیلی بر کشف پدیده‌ای واقعی قلمداد شود، زیرا رخداد آن بر اساس تصادف صرف حتمی است.

مثال کاربردی ۱.۱: محاسبه هتل‌های مشکوک به سبک بونفرونی

فرض کنید سازمان امنیت ملی می‌خواهد افرادی را که مظنون به اقدامات هماهنگ تروریستی هستند با ردیابی محل اقامت آنها شناسایی کند. سناریوی زیر در اسلایدهای درس و فصل اول کتاب مطرح شده است:

- تعداد افراد تحت نظر: 10^9 نفر (یک میلیارد نفر).
 - بازه زمانی رصد: ۱۰۰۰ روز.
 - هر فرد به طور میانگین در ۱٪ روزها (یعنی از هر ۱۰۰ روز، ۱ روز) در یک هتل اقامت می‌کند. بنابراین در طول ۱۰۰۰ روز، هر فرد به طور تصادفی در ۱۰ روز به هتل می‌رود.
 - هر هتل گنجایش دقیقاً ۱۰۰ مسافر دارد.
 - چون در هر روز $10^9 \times 0.01 = 10^7$ نفر در هتل‌ها هستند، به تعداد $10^7 / 100 = 10^5$ هتل نیاز است.
 - تعریف مظنون: هر زوج از افراد نامرتب که حداقل در دو روز متمایز در یک هتل یکسان اقامت کرده باشند.
- پرسش: اگر همه افراد کاملاً رفتاری تصادفی داشته باشند و هیچ توطئه‌ای در کار نباشد، چه تعداد «زوج مظنون» در این داده‌ها ظاهر خواهد شد؟
حل گام‌به‌گام:

۱. تعداد کل زوج‌های ممکن:

$$\binom{10^9}{2} = \frac{10^9 \times (10^9 - 1)}{2} \approx 5 \times 10^{17} \text{ زوج} \quad (2.1)$$

۲. احتمال حضور دو فرد A و B در یک روز خاص در هتل یکسان: احتمال اینکه A در هتل باشد 0.01 ، و احتمال اینکه B در هتل باشد نیز 0.01 است. چون 10^5 هتل وجود دارد، احتمال اینکه هر دو در یک هتل خاص اقامت کنند برابر با $1/10^5$ است. بنابراین، احتمال اقامت همزمان در یک هتل در یک روز معین:

$$p_1 = 10^{-2} \times 10^{-2} \times 10^5 = 10^{-9} \quad (3.1)$$

۳. احتمال اقامت در دو روز یکسان: احتمال اینکه این دو نفر در دو روز خاص هم‌هتل شوند $p_1^2 = 10^{-18}$ است. تعداد جفت‌روزهای ممکن از میان ۱۰۰۰ روز برابر است با:

$$\binom{1000}{2} = \frac{1000 \times 999}{2} \approx 5 \times 10^5 \quad (4.1)$$

بنابراین، احتمال اینکه دو فرد تصادفی حداقل در دو روز در یک هتل اقامت داشته باشند:

$$p_2 = \binom{1000}{2} \times (10^{-9})^2 = (5 \times 10^5) \times 10^{-18} = 5 \times 10^{-13} \quad (5.1)$$

۴. امید ریاضی تعداد زوج‌های مظنون کاذب: تعداد زوج‌های مظنون مورد انتظار از حاصل ضرب تعداد کل زوج‌ها در احتمال p_2 حاصل می‌شود:

$$E = (5 \times 10^{17}) \times (5 \times 10^{-13}) = 250,000! \text{ زوج مظنون} \quad (6.1)$$

نتیجه‌گیری تحلیلی: در این داده‌ها، ۲۵۰ هزار جفت فرد کاملاً بی‌گناه شناسایی می‌شوند که تصادفاً دو بار در یک هتل اقامت داشته‌اند. اگر تیم امنیتی بخواهد تمامی این ۲۵۰ هزار زوج را بازجویی کند، دچار فلج عملیاتی خواهد شد. این مثال اثبات می‌کند که در کلان‌داده، یافتن همبستگی بدون پشتوانه آماری و شواهد کمکی، به نتایج فاجعه‌بار منجر می‌شود.

نکته امتحانی و کلیدی

در آزمون‌های درس کلان داده، مسائل مبتنی بر اصل بونفرونی بسیار پرکاربرد هستند. به خاطر بسپارید که کلید حل این مسائل در سه گام خلاصه می‌شود: ۱. محاسبه تعداد کل ترکیبات نامزدها (N) ؛ ۲. محاسبه احتمال رخداد تصادفی رویداد مورد نظر برای یک نامزد (p) ؛ ۳. محاسبه امید ریاضی $E = N \times p$. چنانچه $E \geq 1$ باشد، الگو غیرقابل استناد به عنوان ناهنجاری است.

۴.۱ مفاهیم کمکی و ابزارهای ضروری برای کلان داده

۱.۴.۱ معیار اهمیت کلمات در اسناد: TF-IDF

در بازیابی اطلاعات و کاوش متون، لازم است کلمات کلیدی اسناد را بدون دخالت کلمات پرتکرار و بی‌ارزش (نظیر حروف اضافه و ربط) شناسایی کرد. برای این منظور از شاخص TF-IDF^{۱۵} استفاده می‌شود. فرض کنید مجموعه‌ای از N سند متنی داریم. برای واژه t در سند d :

۱. فراوانی واژه (TF): نسبت تعداد دفعات تکرار واژه t در سند d ($f_{t,d}$) به بیشترین تعداد تکرار هر واژه‌ای در همان سند:

$$TF(t, d) = \frac{f_{t,d}}{\max_{w \in d} f_{w,d}} \quad (۷.۱)$$

این نرمال‌سازی مانع از آن می‌شود که اسناد طولانی‌تر صرفاً به خاطر طولشان امتیاز بالاتری دریافت کنند.

۲. معکوس فراوانی سند (IDF): اگر کلمه t در n_t سند از کل N سند ظاهر شده باشد، شاخص IDF آن به صورت زیر تعریف می‌شود:

$$IDF(t) = \log_p \left(\frac{N}{n_t} \right) \quad (۸.۱)$$

اگر کلمه‌ای در تمام اسناد تکرار شود ($n_t = N$)، آنگاه $\log_p(1) = 0$ شده و وزن آن کلمه صفر می‌گردد. در مقابل، کلماتی که فقط در چند سند خاص ظاهر شوند، IDF بالایی دریافت می‌کنند.

۳. شاخص ترکیبی TF-IDF:

$$TF-IDF(t, d) = TF(t, d) \times IDF(t) \quad (۹.۱)$$

۲.۴.۱ توابع درهم‌سازی و رفتار آن‌ها

توابع درهم‌سازی^{۱۶} ابزار بنیادین در تمام الگوریتم‌های کلان داده هستند. یک تابع درهم‌سازی $h(x)$ کلیدی دلخواه را به مقداری صحیح در بازه $[0, B-1]$ نگاشت می‌کند. در کلان داده، دو ویژگی حیاتی زیر مورد انتظار است:

- توزیع یکنواخت^{۱۷}: کلیدها به طور مساوی میان B سبد پخش شوند تا از تجمع بار جلوگیری گردد.
- شبه تصادفی بودن^{۱۸}: حتی اگر ورودی‌ها دارای الگوهای منظم باشند، مقادیر درهم‌سازی حاصل رفتاری مشابه متغیرهای تصادفی مستقل نشان دهند.

۳.۴.۱ قوانین توانی و مفهوم دنباله طولانی

در بسیاری از پدیده‌های وب و کلان داده (مانند توزیع درجات در گراف وب، تعداد خریدهای کالاها در آمازون، یا تعداد بازدید ویدئوها در یوتیوب)، داده‌ها از توزیع نرمال گاوسی پیروی نمی‌کنند، بلکه پیرو قانون توانی^{۱۹} هستند:

$$y = c \cdot x^k \quad (k < 0) \quad (۱۰.۱)$$

^{۱۵} Term Frequency - Inverse Document Frequency

^{۱۶} Hash Functions

^{۱۷} Uniform Distribution

^{۱۸} Pseudorandomness

^{۱۹} Power Law

که در مقیاس لگاریتمی به یک خط راست تبدیل می‌شود:

$$\log y = \log c + k \log x \quad (11.1)$$

این توزیع بیانگر پدیده **دنباله طولانی**^{۲۰} است؛ یعنی تعداد بسیار کمی از عناصر دارای فراوانی نجومی هستند (اقلیت پرطرفدار)، اما مجموع حجم عظیمی از داده‌ها در دنباله‌ای از عناصر کم‌تکرار قرار دارد. **قانون زیپف و توزیع پارتو**: یکی از شناخته‌شده‌ترین مصادیق قوانین توانی، **قانون زیپف**^{۲۱} است که بیان می‌دارد فراوانی عنصر با رتبه r ام در میان اقلام به صورت زیر رفتار می‌کند:

$$f(r) \propto \frac{1}{r^\alpha} \quad (\alpha \approx 1) \quad (12.1)$$

به عنوان مثال، پربسامدترین واژه در زبان انگلیسی («the») تقریباً دو برابر دومین واژه («of») و سه برابر سومین واژه («and») تکرار می‌شود. قاعده مشهور **پارتو ۸۰-۲۰** (که در آن ۸۰ درصد خریدهای یک فروشگاه تنها از ۲۰ درصد کالاهای پرفروش ناشی می‌شود) حالت خاصی از همین توزیع‌های توانی با نماهای شیب‌دار است. در سامانه‌های کلان داده، پردازش کارآمد داده‌های دنباله طولانی نیازمند الگوریتم‌های متمایز از پردازش اقلام ابرپرطرفدار است.

جمع‌بندی فصل اول

- داده‌کاوی به معنای کشف الگوهای معتبر، جدید، سودمند و قابل فهم در حجم انبوه داده‌ها است.
- اصل بونفرونی هشدار می‌دهد که جستجوی کورکورانه در میان تعداد حالات نجومی، قطعاً به کشف همبستگی‌های تصادفی و کاذب می‌انجامد.
- شاخص TF-IDF ابزاری اساسی برای ارزیابی اهمیت واژگان در اسناد است.
- توابع درهم‌سازی و قوانین توانی در سراسر فصول بعدی برای طراحی الگوریتم‌های مقیاس‌پذیر به کار گرفته خواهند شد.