

# مبانی و الگوریتم‌های کلان‌داده

جزوه جامع درسی و مرجع دانشگاهی تحلیل کلان‌داده

بر اساس سرفصل‌ها و اسلایدهای کتاب (MMDS) Datasets Massive of Mining  
تألیف: ژوره لسکوک، آناند راجارامان، جفری اولمن

گردآورنده: احسان شهبازی

مجموعه یادداشتهای آموزشی کارشناسی ارشد

۷ مهر ۱۴۰۵

## فصل ۳

# یافتن آیتم‌های مشابه و درهم‌سازی حساس به مکان (LSH)

### ۱.۳ مقدمه و تعریف مسئله

در تحلیل کلان‌داده، یکی از متداول‌ترین نیازمندی‌ها، یافتن آیتم‌هایی است که به یکدیگر «مشابه» هستند. کاربردهای این مسئله بسیار متنوع و گسترده است:


- **تشخیص اسناد تکراری یا تقریباً یکسان**<sup>۱</sup>: شناسایی صفحات آینه‌ای در وب، سرقت ادبی در مقالات، یا اخبار بازنشر شده از یک خبرگزاری در سایت‌های مختلف.
  - **سامانه‌های توصیه‌گر**<sup>۲</sup>: یافتن کاربرانی که سلیقه یا تاریخچه خرید یکسانی در فروشگاه آنلاین دارند.
  - **جستجوی تصاویر مشابه**: بازیابی تصاویری که علیرغم تغییرات اندک در رزولوشن یا کادربندی، محتوای یکسانی دارند.
  - **شناسایی کلاهبرداری**<sup>۳</sup>: یافتن گزارش‌های پزشکی یا خسارت‌های بیمه‌ای با شرح یکسان.
- اگر مجموعه‌ای شامل  $N$  آیتم داشته باشیم، مقایسه دوجه‌دوی تمامی جفت‌ها نیازمند انجام:

$$\binom{N}{2} = \frac{N(N-1)}{2} \approx \frac{N^2}{2} \quad (1.3)$$

مقایسه است. چنانچه  $N = 10^6$  (یک میلیون سند) باشد، تعداد مقایسه‌ها حدود  $5 \times 10^{11}$  خواهد بود. حتی اگر هر مقایسه تنها ۱ میکروثانیه زمان ببرد، اجرای آن نزدیک به ۶ روز به طول می‌انجامد؛ برای  $N = 10^7$ ، این زمان به ۶۰۰ روز افزایش خواهد یافت!

برای حل این چالش بنیادین، یک خط لوله محاسباتی سه‌مرحله‌ای طراحی شده است (شکل ۱.۳):

۱. **شینگلینگ (Shingling)**: تبدیل اسناد متنی به مجموعه‌هایی از توکن‌های متوالی کوتاه.
۲. **کمینه‌سازی درهم‌سازی (Min-Hashing)**: تبدیل مجموعه‌های بسیار بزرگ به امضاهای کوتاه، به نحوی که تشابه مجموعه‌ها حفظ گردد.
۳. **درهم‌سازی حساس به مکان (LSH)**: متمرکز ساختن بررسی‌ها تنها بر روی جفت‌های نامزدی که احتمال شباهت آن‌ها بسیار بالاست، بدون نیاز به مقایسه تمامی جفت‌ها.



شکل ۱.۳: خط لوله استاندارد سه‌مرحله‌ای برای یافتن آیتم‌های مشابه در کلان‌داده

<sup>۱</sup> Near-Duplicate Documents  
<sup>۲</sup> Recommender Systems  
<sup>۳</sup> Fraud Detection

## ۲.۳ گام نخست: شینگلینگ اسناد

برای مقایسه دو سند، نمی‌توان صرفاً به برابری دقیق کلمات نگاه کرد، زیرا تغییر ترتیب چند کلمه یا افزودن یک پاراگراف کوتاه نباید مانع از کشف شباهت شود.

### تعریف ۱.۳: $k$ -شینگل یا $k$ -گرام

یک  $k$ -شینگل<sup>a</sup> برای یک سند متنی، هر زیررشته به طول  $k$  است که در درون آن سند ظاهر می‌شود. شینگل‌ها می‌توانند بر حسب کاراکتر یا واژه تعریف شوند.

<sup>a</sup>Shingle- $k$  یا Gram- $k$

### مثال کاربردی ۱.۳: استخراج شینگل‌ها

فرض کنید سند  $D$  برابر با رشته «abcdabd» باشد و  $k = ۲$  کاراکتر در نظر گرفته شود. مجموعه شینگل‌های موجود در سند عبارت‌اند از:

$$S(D) = \{ab, bc, cd, da, bd\} \quad (۲.۳)$$

توجه نمایید که شینگل «ab» دوبار ظاهر شده است، اما در قالب مجموعه، عناصر تکراری حذف می‌گردند (مگر آنکه از چندمجموعه<sup>a</sup> استفاده شود).

<sup>a</sup>Bag of Shingles

### ۱.۲.۳ انتخاب اندازه مناسب برای $k$

- اگر  $k$  خیلی کوچک انتخاب شود (مثلاً  $k = ۱$  یا  $k = ۲$  در زبان انگلیسی)، تقریباً تمام شینگل‌ها در تمام اسناد تکرار خواهند شد؛ در نتیجه همه اسناد به اشتباه شبیه هم ارزیابی می‌شوند.
- قانون تجربی:  $k$  باید آن‌قدر بزرگ باشد که احتمال حضور تصادفی یک شینگل خاص در سندی نامرتب بسیار اندک باشد. برای اسناد معمولی متنی (ایمیل‌ها و مقالات کوتاه) معمولاً  $k = ۵$  واژه یا  $k = ۹$  کاراکتر انتخاب می‌شود.
- **فشرده‌سازی شینگل‌ها:** برای صرفه‌جویی در مصرف حافظه، هر شینگل با استفاده از یک تابع درهم‌سازی مطمئن به یک عدد صحیح ۴ بیتی (۳۲ بیتی) نگاشت می‌شود؛ بدین ترتیب هر سند به مجموعه‌ای از اعداد ۴ بیتی تبدیل می‌گردد.

## ۳.۳ معیار تشابه جاکارد و ماتریس مشخصه

## تعریف ۲.۳: تشابه جاکارد

تشابه جاکارد<sup>a</sup> میان دو مجموعه  $S$  و  $T$  برابر است با نسبت اندازه اشتراک آن‌ها به اندازه اجتماع آن‌ها:

$$\text{SIM}(S, T) = J(S, T) = \frac{|S \cap T|}{|S \cup T|} \quad (۳.۳)$$

فاصله جاکارد<sup>b</sup> نیز به صورت مکمل تشابه تعریف می‌شود:

$$d_J(S, T) = 1 - J(S, T) = \frac{|S \cup T| - |S \cap T|}{|S \cup T|} \quad (۴.۳)$$

Jaccard Similarity<sup>a</sup>Jaccard Distance<sup>b</sup>

## قضیه ۱.۳: ویژگی متریک فاصله جاکارد

فاصله جاکارد  $d_J(S, T) = 1 - J(S, T)$  یک **متریک ریاضی معتبر** است؛ یعنی هر چهار شرط فضای متریک را ارضا می‌کند:

۱. **نامنفی بودن:**  $d_J(S, T) \geq 0$  (چون  $0 \leq J(S, T) \leq 1$ ).

۲. **انطباق بر خود:**  $d_J(S, T) = 0 \iff S = T$ .

۳. **تقارن:**  $d_J(S, T) = d_J(T, S)$ .

۴. **نامساوی مثلثی:** برای هر سه مجموعه  $S_1, S_2, S_3$ :

$$d_J(S_1, S_3) \leq d_J(S_1, S_2) + d_J(S_2, S_3) \quad (۵.۳)$$

**اثبات نامساوی مثلثی با بهره‌گیری از Min-Hashing:** بر اساس قضیه Min-Hashing، فاصله جاکارد دقیقاً برابر است با احتمال عدم تطابق مقدار هش تصادفی دو مجموعه:

$$d_J(S, T) = \Pr[h(S) \neq h(T)] \quad (۶.۳)$$

حال برای هر سه مجموعه  $S_1, S_2, S_3$ ، اگر  $h(S_1) \neq h(S_3)$  رخ دهد، لزوماً حداقل یکی از دو رویداد  $h(S_1) \neq h(S_2)$  یا  $h(S_2) \neq h(S_3)$  باید اتفاق افتاده باشد (زیرا اگر هر دو جفت برابر بودند، بنا بر اصل تعدی باید  $h(S_1) = h(S_3)$  می‌شد). بنابراین طبق قاعده اجتماع احتمالات:

$$\Pr[h(S_1) \neq h(S_3)] \leq \Pr[h(S_1) \neq h(S_2)] + \Pr[h(S_2) \neq h(S_3)] \quad (۷.۳)$$

که مستقیماً نامساوی مثلثی  $d_J(S_1, S_3) \leq d_J(S_1, S_2) + d_J(S_2, S_3)$  را به اثبات می‌رساند.

## ۱.۳.۳ ماتریس مشخصه (Characteristic Matrix)

اگر تمام شینگل‌های جهان داده را به عنوان سطرهای یک ماتریس و اسناد مختلف را به عنوان ستون‌های آن در نظر بگیریم، **ماتریس مشخصه**<sup>۴</sup> حاصل می‌شود:

$$M_{ij} = \begin{cases} 1 & \text{وجود داشته باشد } j \text{ در سند } i \text{ اگر شینگل} \\ 0 & \text{در غیر این صورت} \end{cases} \quad (۸.۳)$$

این ماتریس در عمل بی‌نهایت تنگ<sup>۵</sup> است و هرگز به طور کامل در حافظه ذخیره نمی‌شود، اما چارچوب مفهومی بسیار روشنی برای تعریف Min-Hashing فراهم می‌آورد.

Characteristic Matrix<sup>۴</sup>  
Sparse<sup>۵</sup>

## ۴.۳ گام دوم: کمینه‌سازی درهم‌سازی (Min-Hashing)

هدف از Min-Hashing فشرده‌سازی ستون‌های بسیار طولانی ماتریس مشخصه به بردارها و امضاهای کوتاه با طول  $n$  (مثلاً  $n = 100$  یا  $200$ ) است، به گونه‌ای که تشابه امضاها دقیقاً برابر با تشابه جاکارد مجموعه‌های اصلی باشد.

### ۱.۴.۳ جایگشت سطرها و تابع Min-Hash

فرض کنید جایگشتی تصادفی  $\pi$  بر روی سطرهای ماتریس مشخصه اعمال کنیم.

#### تعریف ۳.۳: تابع Min-Hash

مقدار  $h_{\pi}(C)$  برای ستون  $C$  برابر است با **شماره نخستین سطر** (در ترتیب جایگشت  $\pi$ ) که مقدار درایه ستون  $C$  در آن سطر برابر با ۱ باشد.

#### قضیه ۲.۳: قضیه بنیادین Min-Hash [ ]

احتمال اینکه مقدار Min-Hash دو ستون  $C_1$  و  $C_2$  با یکدیگر برابر باشد، دقیقاً معادل تشابه جاکارد آن دو ستون است:

$$\Pr[h_{\pi}(C_1) = h_{\pi}(C_2)] = \text{SIM}(C_1, C_2) = J(C_1, C_2) \quad (9.3)$$

**اثبات قضیه:** سطرهای ماتریس مشخصه نسبت به دو ستون  $C_1$  و  $C_2$  به سه دسته تقسیم می‌شوند:

- نوع  $X$ : سطرهایی که در هر دو ستون مقدار ۱ دارند (تعداد:  $|X| = |C_1 \cap C_2|$ ).
- نوع  $Y$ : سطرهایی که در یکی از دو ستون مقدار ۱ و در دیگری ۰ دارند (تعداد:  $|Y| = |C_1 \cup C_2| - |C_1 \cap C_2|$ ).
- نوع  $Z$ : سطرهایی که در هر دو ستون مقدار ۰ دارند.

هنگامی که سطرها را به صورت تصادفی جایگشت می‌دهیم و از بالا به پایین پیمایش می‌کنیم، سطرهای نوع  $Z$  تاثیری در مقدار Min-Hash ندارند زیرا مقدار هر دو ستون صفر است. بنابراین، نخستین سطر که مقدار ۱ در آن دیده می‌شود، یا از نوع  $X$  خواهد بود یا از نوع  $Y$ . مقدار  $h_{\pi}(C_1) = h_{\pi}(C_2)$  خواهد بود اگر و تنها اگر نخستین سطر غیرصفر مشاهده‌شده از نوع  $X$  باشد. احتمال این رخداد برابر است با نسبت تعداد سطرهای نوع  $X$  به کل سطرهای نوع  $X$  و  $Y$ :

$$\Pr[h_{\pi}(C_1) = h_{\pi}(C_2)] = \frac{|X|}{|X| + |Y|} = \frac{|C_1 \cap C_2|}{|C_1 \cup C_2|} = J(C_1, C_2) \quad (10.3)$$

و حکم اثبات می‌شود.

### ۲.۴.۳ الگوریتم شبیه‌سازی Min-Hash بدون اعمال جایگشت فیزیکی

در کلان‌داده، جایگشت دادن فیزیکی میلیاردها سطر ناممکن است. به جای آن، از  $n$  تابع درهم‌سازی مستقل به فرم  $h_i(r) = (a_i r + b_i) \pmod{p}$  استفاده می‌شود. الگوریتم ماتریس امضا به شرح زیر عمل می‌کند:

#### الگوریتم ۱.۳: محاسبه ماتریس امضای Min-Hash

- **ورودی:** ماتریس مشخصه با  $R$  سطر و  $C$  ستون، و  $n$  تابع درهم‌سازی  $h_1, h_2, \dots, h_n$ .
- **خروجی:** ماتریس امضا  $SIG$  با ابعاد  $n \times C$ .
- **مقداردهی اولیه:** برای تمامی درایه‌های ماتریس امضا،  $SIG(i, c) = \infty$  قرار دهید.
- **پیمایش سطر به سطر:** به ازای هر سطر  $r$  از ماتریس مشخصه:
  ۱. مقادیر  $h_1(r), h_2(r), \dots, h_n(r)$  را محاسبه کنید.

۲. به ازای هر ستون  $c$  که در آن سطر مقدار ۱ دارد:

$$SIG(i, c) = \min(SIG(i, c), h_i(r)) \quad \forall i \in \{1, \dots, n\} \quad (11.3)$$


### ۵.۳ گام سوم: درهم‌سازی حساس به مکان (LSH) برای امضاها

حتی پس از تبدیل اسناد به امضاها، اگر بخواهیم تمامی جفت‌امضاها را با یکدیگر مقایسه کنیم، همچنان با هزینه زمانی مرتبه  $O(N^2)$  روبرو هستیم. روش LSH<sup>۶</sup> راهکاری هوشمندانه برای کاهش فضای جستجو است.

#### ۱.۵.۳ روش دسته‌بندی نواری (Banding Technique)

فرض کنید ماتریس امضا دارای  $n$  سطر است. این ماتریس را به  $b$  نوار<sup>۷</sup> تقسیم می‌کنیم، به طوری که هر نوار شامل دقیقاً  $r$  سطر متوالی باشد، یعنی:

$$n = b \times r \quad (12.3)$$



شکل ۲.۳: افراز ماتریس امضا به  $b$  نوار از  $r$  سطر و هش کردن بخش‌های ستون به سطل‌ها

سازوکار الگوریتم به شرح زیر است:

۱. برای هر نوار، یک تابع درهم‌سازی مجزا در نظر می‌گیریم.
۲. قطعه  $r$ -عنصری هر ستون در آن نوار را به یکی از سطل‌های متعدد درهم‌سازی نگاشت می‌کنیم.
۳. **قاعده جفت‌های نامزد:** دو سند  $C_1$  و  $C_2$  به عنوان **جفت نامزد**<sup>۸</sup> اعلام می‌شوند اگر و تنها اگر حداقل در یک نوار، در سطل یکسانی قرار گیرند.
۴. تنها جفت‌های نامزد مورد مقایسه کامل شباهت قرار می‌گیرند.

#### ۲.۵.۳ تحلیل ریاضی منحنی اس-شکل (S-Curve Analysis)

فرض کنید تشابه واقعی جاکارد میان دو سند برابر با  $s = J(C_1, C_2)$  باشد. می‌خواهیم احتمال نامزد شدن این دو سند  $(f(s))$  را محاسبه نماییم:

۱. احتمال اینکه دو ستون در یک سطر خاص از یک نوار توافق داشته باشند:  $s$ .
۲. احتمال اینکه در تمام  $r$  سطر یک نوار خاص توافق داشته باشند (یعنی در آن نوار در یک سطل بیفتند):

$$P(\text{تطابق در نوار خاص}) = s^r \quad (13.3)$$

<sup>۶</sup> Locality-Sensitive Hashing  
<sup>۷</sup> Band  
<sup>۸</sup> Candidate Pair

۳. احتمال اینکه در آن نوار خاص تطابق نداشته باشند:

$$1 - s^r \quad (۱۴.۳)$$

۴. احتمال اینکه در هیچ‌یک از  $b$  نوار تطابق نداشته باشند (عدم توافق در تمام نوارها):

$$(1 - s^r)^b \quad (۱۵.۳)$$

۵. بنابراین، احتمال اینکه در حداقل یک نوار تطابق داشته باشند (شرط نامزدی):

$$f(s) = 1 - (1 - s^r)^b \quad (۱۶.۳)$$

نمودار تابع  $f(s)$  دارای شکل  $S$  است. آستانه شباهت بحرانی  $s^*$  که در آن شیب منحنی بیشترین مقدار است، با تقریب عالی از رابطه زیر به دست می‌آید:

$$s^* \approx \left(\frac{1}{b}\right)^{1/r} \quad (۱۷.۳)$$

اگر تشابه دو سند  $s > s^*$  باشد، احتمال نامزدی آنها به سرعت به ۱ نزدیک می‌شود؛ و اگر  $s < s^*$  باشد، احتمال نامزدی به سرعت به ۰ میل می‌کند.

#### مثال کاربردی ۲.۳: محاسبه احتمال خطای مثبت کاذب و منفی کاذب در LSH

فرض کنید  $n = ۱۰۰$  سطر در ماتریس امضا داریم و آن را به  $b = ۲۰$  نوار با  $r = ۵$  سطر تقسیم کرده‌ایم. آستانه تقریب برابر است با:

$$s^* \approx (1/20)^{1/5} \approx 0.549 \quad (۱۸.۳)$$

حال دو سناریو را بررسی می‌کنیم:

• دو سند با شباهت بالا  $s = 0.8$ :

$$f(0.8) = 1 - (1 - 0.8^5)^{20} = 1 - (1 - 0.32768)^{20} = 1 - (0.67232)^{20} \approx 1 - 0.00035 = 0.99965 \quad (۱۹.۳)$$

یعنی با احتمال ۹۹/۹۶۵٪ این دو سند به درستی شناسایی می‌شوند (تنها ۰/۰۳۵٪ خطای منفی کاذب).

• دو سند با شباهت پایین  $s = 0.2$ :

$$f(0.2) = 1 - (1 - 0.2^5)^{20} = 1 - (1 - 0.00032)^{20} \approx 1 - (1 - 20 \times 0.00032) \approx 0.0064 \quad (۲۰.۳)$$

احتمال اینکه این دو سند نامزد شوند کمتر از ۰/۶۴٪ است (خطای مثبت کاذب بسیار اندک).

## ۶.۳ معیارهای فاصله و خانواده‌های درهم‌سازی حساس به مکان

تشابه جاکارد تنها یکی از معیارهای فاصله است. در کلان‌داده، انواع معیارهای فاصله به کار می‌روند:

#### تعریف ۴.۳: اصول موضوعه یک تابع فاصله (متریک)

یک تابع  $d(x, y)$  یک متریک معتبر است اگر و تنها اگر در چهار شرط زیر صدق کند:

۱. نامنفی بودن:  $d(x, y) \geq 0$ .

۲. تفکیک‌پذیری:  $d(x, y) = 0 \iff x = y$ .

۳. تقارن:  $d(x, y) = d(y, x)$ .

۴. نامساوی مثلثی:  $d(x, z) \leq d(x, y) + d(y, z)$ .

• فاصله اقلیدسی  $(L_2)$ :  $d(x, y) = \sqrt{\sum_i (x_i - y_i)^2}$ .

• فاصله منهتن  $(L_1)$ :  $d(x, y) = \sum_i |x_i - y_i|$ .

• فاصله کسینوسی: زاویه بین دو بردار،  $\theta = \arccos\left(\frac{x \cdot y}{\|x\| \|y\|}\right)$ ، که منجر به روش اَبَرَبَرش‌های تصادفی<sup>۱۰</sup> یا SimHash می‌شود.

• فاصله همینگ<sup>۱۱</sup>: تعداد موقعیت‌هایی که دو رشته با طول برابر در آن‌ها متفاوت‌اند.

#### نکته امتحانی و کلیدی

در آزمون‌ها، نحوه تنظیم پارامترهای  $b$  و  $r$  با توجه به آستانه مورد نظر  $s$  بسیار حائز اهمیت است:

- اگر هدف کاهش منفی کاذب<sup>a</sup> باشد (نمی‌خواهیم هیچ جفت مشابهی جا بیفتد)،  $b$  را افزایش و  $r$  را کاهش می‌دهیم (پایین آوردن آستانه).
- اگر هدف کاهش مثبت کاذب<sup>b</sup> و کاهش زمان محاسبات باشد،  $r$  را افزایش می‌دهیم تا شرط سخت‌گیرانه‌تری برای هم‌سطلی اعمال گردد.

False Negatives<sup>a</sup>  
False Positives<sup>b</sup>

#### جمع‌بندی فصل سوم

- مقایسه دوبه‌دوی اسناد در کلان‌داده به دلیل مرتبه زمانی  $O(N^2)$  غیرممکن است.
- شینگلینگ اسناد را به مجموعه‌هایی مناسب برای ارزیابی تشابه جاکارد تبدیل می‌کند.
- روش Min-Hash با تکیه بر جایگشت‌های تصادفی، مجموعه‌های حجیم را به امضاهایی کوتاه فشرده می‌سازد به نحوی که  $\Pr[h(C_1) = h(C_2)] = J(C_1, C_2)$ .
- الگوریتم LSH با تقسیم ماتریس امضا به  $b$  نوار از  $r$  سطر و ایجاد منحنی، شکل-S فضای جستجو را تنها به نامزدهای بسیار محتمل محدود می‌سازد.