

مبانی و الگوریتم‌های کلان‌داده

جزوه جامع درسی و مرجع دانشگاهی تحلیل کلان‌داده

بر اساس سرفصل‌ها و اسلایدهای کتاب (MMDS) Datasets Massive of Mining
تألیف: ژوره لسکوک، آناند راجارامان، جفری اولمن

گردآورنده: احسان شهبازی

مجموعه یادداشتهای آموزشی کارشناسی ارشد

۷ مهر ۱۴۰۵

فصل ۵

تحلیل پیوندها و رتبه‌بندی وب (Link Analysis & PageRank)

۱.۵ مقدمه: گراف وب و چالش بازیابی اطلاعات

در روزهای آغازین وب، موتورهای جستجوی اولیه (نظیر Altavista و Lycos) اسناد را صرفاً بر پایه تطابق متنی و شمارش کلمات کلیدی (مشابه شاخص TF-IDF) رتبه‌بندی می‌کردند. این رویکرد به سرعت با شکست مواجه شد؛ زیرا طراحان سایت‌ها با تکرار هزاران باره کلمات کلیدی پر جستجو با رنگ سفید در پس‌زمینه سفید، نتایج موتورهای جستجو را فریب می‌دادند (پدیده هرزنامه متنی وب^۱).

انقلاب واقعی زمانی رخ داد که لری پیج و سرگئی برین، بنیان‌گذاران گوگل، دریافتند که وب صرفاً مجموعه‌ای از اسناد متنی مجزا نیست، بلکه یک **گراف جهت‌دار عظیم** است که در آن:


• گره‌ها صفحات وب هستند.

• یال‌های جهت‌دار، ابرپیوندها^۲ میان صفحات هستند.

ایده بنیادین این بود: یک پیوند از صفحه A به صفحه B ، به منزله یک **رای اعتماد**^۳ از سوی نویسنده صفحه A به کیفیت و اعتبار صفحه B است. با این حال، ارزش همه آرا یکسان نیست؛ رای صفحه‌ای معتبر و شناخته‌شده (نظیر دانشگاه استنفورد یا یاهو) باید وزن بسیار بیشتری نسبت به رای یک وبلاگ تازه‌تأسیس داشته باشد. این بینش ریاضی، اساس الگوریتم **PageRank** [۱۱] را تشکیل می‌دهد.

۲.۵ ساختار کلان گراف وب: مدل پاپیونی (Bow-Tie Model)

تحقیقات تجربی بر روی ساختار گراف وب نشان داده است که این گراف دارای یک ساختار منسجم به نام **مدل پاپیونی**^۴ است (شکل ۱.۵):



شکل ۱.۵: مدل پاپیونی ساختار گراف جهانی وب (Web Graph Bow-Tie Architecture)

اجزای ساختار پاپیونی عبارت‌اند از:

- Web Term Spam^۱
- Hyperlinks^۲
- Vote of Confidence^۳
- Bow-Tie Architecture^۴

۱. **هسته متصل قوی (SCC):** بخشی از گراف که میان هر دو صفحه آن، یک مسیر جهت‌دار دوطرفه وجود دارد (قلب تپنده وب).
۲. **بخش ورودی (IN):** صفحاتی که می‌توان از آن‌ها به SCC رسید، اما هیچ مسیری از SCC به آن‌ها وجود ندارد (مانند سایت‌های شخصی جدید).
۳. **بخش خروجی (OUT):** صفحاتی که از طریق SCC قابل دسترسی هستند، اما هیچ پیوندی به عقب باز نمی‌گردانند (مانند صفحات قوانین یا دانلود فایل).
۴. **پیچک‌ها و لوله‌ها (Tendrils & Tubes):** لوله‌ها مسیرهای مستقیمی هستند که بدون عبور از SCC، مستقیماً بخش IN را به OUT متصل می‌کنند؛ پیچک‌ها مسیرهای بن‌بست آویزان به بخش‌های جانبی هستند.

۳.۵ فرمول‌بندی ریاضی الگوریتم PageRank

تعریف ۱.۵: رتبه‌بندی صفحه (PageRank) اولیه

فرض کنید گراف وب دارای N صفحه باشد. رتبه صفحه j که با r_j نشان داده می‌شود، برابر است با مجموع سهم رتبه‌های صفحاتی که به j پیوند داده‌اند:

$$r_j = \sum_{i \rightarrow j} \frac{r_i}{d_i} \quad (1.5)$$

که در آن d_i بیانگر **درجه خروجی^a** صفحه i است؛ یعنی صفحه i رتبه خود را به طور مساوی میان تمامی لینک‌های خروجی‌اش توزیع می‌کند.

Out-degree^a

۱.۳.۵ بیان ماتریسی و بردار ویژه

برای فرمول‌بندی مسئله در قالب جبر خطی، **ماتریس انتقال تصادفی^۵** M با ابعاد $N \times N$ را تعریف می‌کنیم:

$$M_{ji} = \begin{cases} \frac{1}{d_i} & \text{وجود داشته باشد } j \text{ به } i \text{ اگر پیوند جهت‌دار از } i \text{ به } j \\ 0 & \text{در غیر این صورت} \end{cases} \quad (2.5)$$

توجه فرمایید که ستون‌های ماتریس M جمع‌شان برابر با ۱ است (ماتریس ستون-تصادفی). معادله توزیع رتبه به فرم ماتریسی زیر بازنویسی می‌شود:

$$r = M \cdot r \quad (3.5)$$

این معادله نشان می‌دهد که بردار PageRank (r)، در واقع **بردار ویژه راست متناظر با مقدار ویژه $\lambda = 1$** برای ماتریس انتقال M است. طبق نظریه زنجیره‌های مارکوف، این بردار همان **توزیع پایدار^۶** یک گردش تصادفی^۷ بی‌نهایت در گراف وب است.

۲.۳.۵ الگوریتم تکرار توانی (Power Iteration)

برای محاسبه بردار رتبه در مقیاس وب، از روش تکرار توانی استفاده می‌شود:

Stochastic Transition Matrix^۵
Stationary Distribution^۶
Random Walk^۷

الگوریتم ۱.۵: محاسبه PageRank با روش تکرار توانی

• **مقداردهی اولیه:** بردار رتبه به صورت یکنواخت مقداردهی می‌شود:

$$r^{(0)} = \left[\frac{1}{N}, \frac{1}{N}, \dots, \frac{1}{N} \right]^T \quad (۴.۵)$$

• **تکرار گام‌ها:** در هر مرحله $t + 1$:

$$r^{(t+1)} = M \cdot r^{(t)} \quad (۵.۵)$$

• **شرط توقف:** تا زمانی که تغییر بردار کمتر از آستانه خطا شود: $\|r^{(t+1)} - r^{(t)}\|_1 < \epsilon$ (معمولاً ۵۰ تا ۱۰۰ تکرار برای همگرایی کامل کافی است).

قضیه ۱.۵: نرخ همگرایی تکرار توانی و دومین مقدار ویژه

ماتریس تصادفی گوگل $A = \beta M + (1 - \beta) \frac{1}{n} ee^T$ یک ماتریس تصادفی ستونی مارکوف، مثبت، کاهش‌ناپذیر و نامتناوب است. طبق قضیه پرون-فرو Frobenius-Perron:

۱. بزرگ‌ترین مقدار ویژه این ماتریس دقیقاً یکتا و برابر با $\lambda_1 = 1$ است.

۲. قدرمطلق دومین مقدار ویژه ماتریس از ضریب میرایی تبعیت می‌کند: $|\lambda_2| \leq \beta$.

۳. پس از k گام تکرار توانی، مولفه خطا با نرخ هندسی β^k منقبض می‌شود:

$$\|r^{(k)} - r^*\| \leq C \cdot \beta^k \quad (۶.۵)$$

با انتخاب متداول $\beta = ۰.۸۵$ ، پس از ۵۰ تکرار مقدار خطا به زیر $۰.۰۰۰۳ \approx ۰.۸۵^{۵۰}$ رسیده و مستقل از تعداد میلیاردها صفحه وب، همگرایی تضمین می‌گردد.

۴.۵ ناهنجاری‌های گراف وب و راهکارهای اصلاحی


الگوریتم ساده فوق در مواجهه با ساختار واقعی وب با دو آسیب ساختاری مرگبار روبرو می‌شود:

۱.۴.۵ ۱. تله‌های عنکبوتی (Spider Traps)

تله عنکبوتی به مجموعه‌ای از صفحات گفته می‌شود که پیوندهایی میان خود دارند، اما هیچ پیوند خروجی به سایر صفحات وب ندارند (شکل ۲.۵). در هنگام گردش تصادفی، وب‌گرد وارد این حلقه شده و دیگر هرگز نمی‌تواند از آن خارج شود. در نتیجه تکرار توانی، تمامی رتبه صفحات وب جذب این تله شده و رتبه سایر صفحات به سمت صفر میل می‌کند!


۲.۴.۵ ۲. بن‌بست‌ها (Dead Ends)

بن‌بست صفحه‌ای است که هیچ پیوند خروجی ندارد ($d_i = 0$). در این حالت، ستون متناظر در ماتریس M کاملاً صفر خواهد بود؛ در نتیجه مجموع مقادیر بردار رتبه در هر تکرار کاهش می‌یابد و اصطلاحاً رتبه وب «نشت» کرده و در نهایت صفر می‌شود.



تله عنکبوتی:

رتبه درون حلقه محبوس می‌شود



بن‌بست:

صفحه D لینک خروجی ندارد

شکل ۲.۵: دو چالش اساسی گردش تصادفی: تله عنکبوتی و بن‌بست

۵.۵ الگوریتم نهایی گوگل با تله‌پورتیشن (مالیات‌گیری)

برای رفع تله‌های عنکبوتی و بن‌بست‌ها، مدل گردشگر تصادفی با جهش^۸ ابداع شد.

تعریف ۲.۵: فرمول نهایی PageRank

فرض می‌کنیم وب‌گرد در هر گام:

- با احتمال β ، یکی از لینک‌های خروجی صفحه جاری را به صورت تصادفی دنبال می‌کند.
- با احتمال $1 - \beta$ ، تصمیم می‌گیرد جهش کند (تله‌پورت شود) و به صورت کاملاً تصادفی و یکنواخت به یکی از N صفحه موجود در سراسر وب برود.

معادله به‌روزرسانی رتبه به فرم زیر اصلاح می‌گردد:

$$r = \beta Mr + \frac{1 - \beta}{N} \mathbf{1} \quad (۷.۵)$$

که در آن $\mathbf{1}$ بردار ستونی از تماماً یک‌ها به طول N است. ضریب β معمولاً در بازه ۰.۸ تا ۰.۸۵ تنظیم می‌شود.

اگر صفحه‌ای بن‌بست باشد ($d_i = ۰$)، فرض می‌شود که با احتمال مساوی $1/N$ به تمام صفحات وب پیوند دارد؛ در نتیجه ماتریس اصلاح‌شده کاملاً تصادفی و غیرقابل تقلیل^۹ شده و بر اساس قضیه پرن-فروبنیوس^{۱۰}، همگرایی به بردار ویژه یکتای مثبت تضمین می‌گردد.

مثال کاربردی ۱.۵: محاسبه عددی PageRank با تله‌پورتیشن

فرض کنید گرافی با ۳ صفحه A, B, C داریم که در آن: $A \rightarrow B, C$ ، $B \rightarrow C$ ، و $C \rightarrow A$. ماتریس انتقال M :

$$M = \begin{bmatrix} 0 & 0 & 1 \\ 1/2 & 0 & 0 \\ 1/2 & 1 & 0 \end{bmatrix} \quad (۸.۵)$$

با فرض $\beta = ۰.۸$ ، بردار اولیه $r^{(۰)} = [1/3, 1/3, 1/3]^T$ است. سهم تله‌پورتیشن برابر با $۰.۰۶۷ = \frac{1-\beta}{3} \approx \frac{۰.۲}{3}$ خواهد بود. در گام اول تکرار:

$$r^{(1)} = ۰.۸ \begin{bmatrix} 0 & 0 & 1 \\ 1/2 & 0 & 0 \\ 1/2 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1/3 \\ 1/3 \\ 1/3 \end{bmatrix} + \begin{bmatrix} ۰.۰۶۷ \\ ۰.۰۶۷ \\ ۰.۰۶۷ \end{bmatrix} = \begin{bmatrix} ۰.۲۶۷ + ۰.۰۶۷ \\ ۰.۱۳۳ + ۰.۰۶۷ \\ ۰.۴۰۰ + ۰.۰۶۷ \end{bmatrix} = \begin{bmatrix} ۰.۳۳۴ \\ ۰.۲۰۰ \\ ۰.۴۶۷ \end{bmatrix} \quad (۹.۵)$$

با ادامه تکرارها، صفحه C بالاترین رتبه را کسب می‌کند زیرا از هر دو صفحه A و B لینک دریافت می‌نماید.

۶.۵ الگوریتم‌های پیشرفته: رتبه‌بندی حساس به موضوع و TrustRank

۱.۶.۵ PageRank وابسته به موضوع (Topic-Sensitive PageRank)

اگر کاربری واژه «جاوا» را جستجو کند، آیا به دنبال جزیره جاوا در اندونزی است یا زبان برنامه‌نویسی جاوا؟ در Topic-Sensitive PageRank، به جای آنکه احتمال تله‌پورتیشن به صورت یکنواخت میان تمام صفحات تقسیم شود، وب‌گرد تنها به مجموعه‌ای از صفحات معتبر مرتبط با آن موضوع خاص (مجموعه S) جهش می‌کند:

$$r = \beta Mr + (1 - \beta) \frac{e_S}{|S|} \quad (۱۰.۵)$$

که در آن e_S برداری است که درایه‌های متعلق به مجموعه S برابر با ۱ و سایر درایه‌ها صفر است.

Random Surfer with Teleportation^۸
Irreducible^۹
Perron-Frobenius Theorem^{۱۰}

۲.۶.۵ مبارزه با مزارع اسپم با TrustRank

یک مزرعه اسپم^{۱۱} شامل یک صفحه هدف t و میلیون‌ها صفحه جعلی ساخته‌شده توسط اسپمر است که همگی به t لینک می‌دهند تا رتبه آن را به طور مصنوعی بالا ببرند. الگوریتم TrustRank برای مقابله با این پدیده:

۱. مجموعه‌ای از صفحات با اعتماد قطعی (دامنه‌های دانشگاهی edu و دولتی gov) توسط داوران انسانی انتخاب می‌شوند.

۲. الگوریتم تله‌پورتیشن تنها جهش به این صفحات معتبر را مجاز می‌داند.

۳. صفحات اسپم چون دور از صفحات معتبر هستند، نمره اعتماد (Trust) نزدیک به صفر دریافت می‌کنند.

۷.۵ الگوریتم قطب‌ها و مراجع (HITS)

الگوریتم HITS که توسط جان کلینبرگ ابداع شد [۹]، دیدگاهی دوگانه نسبت به اهمیت صفحات ارائه می‌دهد:

تعریف ۳.۵: قطب‌ها و مراجع

- **مرجع (Authority):** صفحه‌ای با محتوای عمیق و ارزشمند درباره یک موضوع (دارای نمره a).
- **قطب (Hub):** صفحه‌ای که خود محتوای خاصی ندارد، اما لینک‌های فوق‌العاده‌ای به مراجع معتبر ارائه می‌دهد (نظیر صفحات فهرست پیوندها یا دایرکتوری‌ها، دارای نمره h).

رابطه بازگشتی میان قطب و مرجع:

$$a = A^T \cdot h \quad (۱۱.۵)$$

$$h = A \cdot a \quad (۱۲.۵)$$

که در آن A ماتریس مجاورت گراف است ($A_{ij} = 1$ اگر پیوند از i به j باشد). با ترکیب این دو رابطه:

$$a = A^T(Aa) = (A^T A)a, \quad h = A(A^T h) = (AA^T)h \quad (۱۳.۵)$$

یعنی بردار مراجع، بردار ویژه ماتریس AA^T و بردار قطب‌ها، بردار ویژه ماتریس AA^T است!

نکته امتحانی و کلیدی

مقایسه کلیدی میان PageRank و HITS در آزمون‌ها:

۱. **استقلال از پرس‌وجو:** PageRank مستقل از پرس‌وجو بوده و به صورت آفلاین برای کل وب محاسبه می‌شود؛ اما HITS وابسته به پرس‌وجو است و بر روی زیرگراف حاصل از نتایج اولیه جستجو محاسبه می‌گردد.

۲. **حساسیت به اسپم:** HITS به شدت نسبت به دستکاری لینک‌ها (افزودن لینک‌های متقابل قطبی) آسیب‌پذیرتر از PageRank است.

جمع‌بندی فصل پنجم

- وب یک گراف جهت‌دار با معماری پاپیونی است.
- الگوریتم PageRank با مدل‌سازی گردش تصادفی، اعتبار ساختاری صفحات را می‌سنجد.
- تله‌های عنکبوتی و بن‌بست‌ها با سازوکار تله‌پورتیشن تصادفی (β) درمان می‌شوند.
- الگوریتم‌های PageRank Topic-Sensitive و TrustRank رتبه‌بندی را برای موضوعات و جلوگیری از اسپم شخصی‌سازی می‌کنند.

• الگوریتم HITS صفحات را به دو طبقه مراجع و قطب‌ها تفکیک می‌نماید.