

مبانی و الگوریتم‌های کلان‌داده

جزوه جامع درسی و مرجع دانشگاهی تحلیل کلان‌داده

بر اساس سرفصل‌ها و اسلایدهای کتاب (MMDS) Datasets Massive of Mining
تألیف: ژوره لسکوک، آناند راجارامان، جفری اولمن

گردآورنده: احسان شهبازی

مجموعه یادداشت‌های آموزشی کارشناسی ارشد

۷ مهر ۱۴۰۵

فصل ۸

تبلیغات برخط در وب (Online Advertising & AdWords)

۱.۸ مقدمه: الگوریتم‌های برخط و اقتصاد موتورهای جستجو

درآمد اصلی غول‌های فناوری وب (به‌ویژه گوگل و متا) از تبلیغات هدفمند اینترنتی حاصل می‌شود. تفاوت بنیادین تبلیغات سنتی (نظیر بیلبرد یا آگهی روزنامه) با تبلیغات وب در دو عامل خلاصه می‌شود:

۱. **هدفمندی مستقیم**^۱: نمایش تبلیغ متناسب با نیاز دقیق لحظه‌ای کاربر بر اساس پرس‌وجوی جستجو^۲.
 ۲. **الگوریتم‌های برخط**^۳: ورودی‌های مسئله (پرس‌و‌جوه‌ای کاربران) یکی‌یکی در طول زمان وارد می‌شوند و الگوریتم باید بلافاصله، بدون اطلاع از آینده و به صورت بازگشت‌ناپذیر تصمیم بگیرد که کدام آگهی را نمایش دهد.
- در الگوریتم‌های سنتی، کل ورودی از ابتدا معلوم است (الگوریتم آفلاین)، اما در الگوریتم‌های برخط، تصمیم‌گیری در شرایط نااطمینانی صورت می‌پذیرد.

تعریف ۱.۸: نسبت رقابتی (Competitive Ratio)

کارایی یک الگوریتم برخط در مقایسه با یک الگوریتم بهینه آفلاین (که با برخورداری از ویژگی «پیش‌گویی»، تمام آینده را می‌داند) با معیاری به نام **نسبت رقابتی**^۴ ارزیابی می‌شود:

$$CR = \min_{I \text{ ورودی‌های ممکن}} \frac{\text{سود الگوریتم برخط}(I)}{\text{سود الگوریتم بهینه آفلاین}(I)} \quad (1.8)$$

نسبت رقابتی مقداری بین ۱ و ∞ است. هرچه این نسبت به ۱ نزدیک‌تر باشد، عملکرد الگوریتم برخط بهتر است.

Competitive Ratio^۵

۲.۸ مسئله تطابق دوبخشی برخط (Online Bipartite Matching)

مسئله نمایش تبلیغات را می‌توان در قالب یک گراف دوبخشی $G = (U, V, E)$ مدل‌سازی کرد:

- بخش U : تبلیغ‌دهندگان^۴ که از قبل در سیستم ثبت‌نام کرده‌اند و ثابت هستند.
- بخش V : پرس‌و‌جوه‌ای کاربران^۵ که یکی‌یکی به صورت آنلاین وارد می‌شوند.
- یال (u, v) : نشان می‌دهد که تبلیغ‌دهنده u تمایل به نمایش آگهی برای پرس‌وجوی v دارد.

Targeted Advertising^۱
Search Query^۲
Online Algorithms^۳
Advertisers^۴
Queries^۵

هدف: یافتن بزرگ‌ترین تطابق^۶؛ یعنی بیشترین تعداد یال‌های بدون رأس مشترک.

۱.۲.۸ الگوریتم حریصانه (Greedy Algorithm) و تحلیل نسبت رقابتی

ساده‌ترین استراتژی برخط، الگوریتم حریصانه است: به محض ورود یک پرس‌وجو v ، آن را به هر تبلیغ‌دهنده متصل به آن که تاکنون آگهی به او تخصیص داده نشده، اختصاص می‌دهیم.

قضیه ۱.۸: کران نسبت رقابتی الگوریتم حریصانه

نسبت رقابتی الگوریتم حریصانه برای تطابق دوبخشی برخط حداقل برابر با $\frac{1}{2}$ (۵۰٪) است و این کران تنگ است.

اثبات قضیه: فرض کنید تطابق تولیدشده توسط الگوریتم حریصانه M_{greedy} و تطابق بهینه آفلاین M_{opt} باشد. می‌دانیم هر یال $(u, v) \in M_{\text{opt}}$ باید حداقل با یکی از یال‌های M_{greedy} در رأس u یا v اشتراک داشته باشد (در غیر این صورت الگوریتم حریصانه می‌توانست یال (u, v) را به تطابق خود بیفزاید که با حریصانه بودن آن در تناقض است). چون هر یال در M_{greedy} حداکثر می‌تواند دو سر دو یال مختلف در M_{opt} را لمس کند:

$$|M_{\text{opt}}| \leq 2 \times |M_{\text{greedy}}| \implies \frac{|M_{\text{greedy}}|}{|M_{\text{opt}}|} \geq \frac{1}{2} \quad (۲.۸)$$

بنابراین الگوریتم حریصانه همیشه حداقل نیمی از سود حالت ایده‌آل را کسب می‌کند.

۳.۸ الگوریتم BALANCE با پیشنهادهای برابر

در جهان واقعی، هر تبلیغ‌دهنده دارای یک **بودجه روزانه**^۷ مشخص (مثلاً B دلار) است. اگر پیشنهاد قیمت همه تبلیغ‌دهندگان برای کلمات کلیدی یکسان باشد (مثلاً ۱ دلار به ازای هر کلیک)، استراتژی حریصانه دخواه ممکن است بودجه برخی تبلیغ‌دهندگان را زودتر از موعد تمام کرده و پرس‌و‌جوه‌های بعدی را بدون مشتری باقی بگذارد.

الگوریتم ۱.۸: الگوریتم تعادل (BALANCE)

هنگامی که پرس‌وجوی q وارد می‌شود:

۱. تمامی تبلیغ‌دهندگانی را که برای q پیشنهاد داده‌اند و هنوز بودجه آن‌ها تمام نشده است پیدا کنید.
۲. آگهی را به تبلیغ‌دهنده‌ای اختصاص دهید که **بیشترین بودجه باقیمانده** را دارد (در صورت تساوی، یکی را تصادفی انتخاب کنید).

قضیه ۲.۸: نسبت رقابتی الگوریتم BALANCE

برای مسئله تخصیص آگهی با پیشنهادهای برابر و بودجه‌های متناهی، نسبت رقابتی الگوریتم BALANCE برابر است با:

$$CR = 1 - \frac{1}{e} \approx 0.۶۳۲ \quad (۶۳.۲\%) \quad (۳.۸)$$

این عدد نشان‌دهنده بهبود چشمگیر نسبت به الگوریتم حریصانه ساده (۵۰٪) است.

۴.۸ مسئله عمومی AdWords در گوگل (پیشنهادهای نابرابر)

در سازوکار واقعی سیستم AdWords:

- هر تبلیغ‌دهنده i برای پرس‌وجوی q پیشنهاد قیمت متفاوتی به نام b_{iq} ارائه می‌دهد.

- هر تبلیغ‌دهنده بودجه کل روزانه متفاوتی مانند B_i دارد.
- هدف، بیشینه‌سازی کل درآمد ارزی کسب‌شده از کلیک‌هاست.

۱.۴.۸ تابع امتیازدهی عمومی AdWords

اگر صرفاً به بیشترین پیشنهاد (b_{iq}) توجه کنیم، بودجه تبلیغ‌دهندگان بزرگ خیلی سریع مصرف شده و در ساعات پایانی روز درآمد افت می‌کند. از این رو، الگوریتم عمومی از یک تابع تنزیل غیرخطی استفاده می‌نماید. فرض کنید m_i مقدار پولی باشد که تبلیغ‌دهنده i تاکنون خرج کرده است. کسر بودجه مصرف‌شده برابر با $f_i = m_i/B_i$ است. هنگام ورود پرس‌وجوی q ، تبلیغ‌دهنده برنده بر اساس بیشینه امتیاز ترکیب‌شده انتخاب می‌شود:

$$\Psi_i(q) = b_{iq} \times (1 - e^{-(1-f_i)}) \quad (۴.۸)$$

• اگر تبلیغ‌دهنده‌ای تقریباً تمام بودجه‌اش دست‌نخورده باشد ($f_i \approx 0$)، ضریب تصحیح نزدیک به $1 - 1/e \approx 0.۶۳$ است.

• هرچه بودجه به اتمام نزدیک‌تر شود ($f_i \rightarrow 1$)، ضریب $1 - e^0 = 0$ شده و اولویت آن به شدت کاهش می‌یابد تا فضا برای سایرین باز شود.

اثبات شده است که این الگوریتم تعمیم‌یافته نیز نسبت رقابتی $1 - 1/e$ را تضمین می‌نماید.

۲.۴.۸ نرخ کلیک (CTR) و رتبه‌بندی آگهی‌ها

موتور جستجو تنها در صورتی درآمد کسب می‌کند که کاربر واقعاً بر روی آگهی کلیک نماید (مدل CPC^۸). بنابراین، ارزش انتظاری یک آگهی برابر است با:

$$\text{Revenue Expected} = \text{Bid} \times \text{CTR} \quad (۵.۸)$$

که در آن CTR^۹ نسبت تعداد کلیک‌ها به تعداد نمایش آگهی است. آگهی‌ها بر اساس حاصل‌ضرب پیشنهاد در نرخ کلیک تاریخی (و نمره کیفیت متن آگهی) رتبه‌بندی می‌شوند.

۳.۴.۸ سازوکار حراج قیمت دوم (Vickrey-Clarke-Groves Auction)

گوگل برای ترغیب تبلیغ‌دهندگان به اعلام ارزش واقعی خود، از حراج قیمت دوم تعمیم‌یافته^{۱۰} استفاده می‌کند: برنده حراج، بالاترین پیشنهاد را ثبت کرده است، اما مبلغی که در ازای هر کلیک می‌پردازد برابر با پیشنهاد خودش نیست؛ بلکه برابر است با حداقل مبلغی که برای شکست دادن پیشنهاد رقیب رتبه پایین‌تر لازم بوده است.

قضیه ۳.۸: راست‌گویی به عنوان استراتژی مسلط در حراج قیمت دوم

در حراج قیمت دوم، اعلام ارزش واقعی کالا توسط پیشنهاددهنده ($b = v$) یک استراتژی اکیداً مسلط^{۱۱} است و هیچ عاملی نمی‌تواند با بیش‌برآورد یا کم‌برآورد سود خود را افزایش دهد.

Dominant Strategy^۸

اثبات نظریه بازی‌ها: فرض کنید بالاترین پیشنهاد سایر رقبا برابر با p باشد:

۱. اگر بازیکن بیش‌اظهاری کند ($b > v$): تنها زمانی نتیجه تغییر می‌کند که پیشنهاد رقیب در بازه $v < p < b$ قرار گیرد. در این حالت، بازیکن برنده حراج می‌شود اما باید مبلغ p را بپردازد که از ارزش واقعی کالا (v) بیشتر است؛ یعنی سود خالص منفی ($v - p < 0$) نصیبش می‌گردد.

۲. اگر بازیکن کم‌اظهاری کند ($b < v$): تنها زمانی نتیجه تغییر می‌کند که پیشنهاد رقیب در بازه $b < p < v$ قرار گیرد. در این حالت، بازیکن فرصت برنده شدن در حراجی با سود خالص مثبت ($v - p > 0$) را از دست می‌دهد.

^۸ Cost Per Click

^۹ Click-Through Rate

^{۱۰} Generalized Second-Price (GSP) Auction

بنابراین، در تمامی حالات، ارائه پیشنهاد برابر با ارزش واقعی ($b = v$) بهترین نتیجه ممکن را برای شرکت‌کننده تضمین می‌نماید.

نکته امتحانی و کلیدی

نکات پرکاربرد امتحانی در مبحث تبلیغات وب:

۱. کران پایینی الگوریتم حریصانه همیشه $1/2$ است و بدترین حالت آن زمانی رخ می‌دهد که یک تبلیغ‌دهنده مشترک میان دو پرس‌وجو، با اولین پرس‌وجو اشباع شود و پرس‌وجوی دوم بی‌مشتري بماند.
۲. عدد طلایی $1 - 1/e$ حد بالای تئوریک الگوریتم‌های برخط بدون اطلاع از توزیع ورودی‌ها است.

جمع‌بندی فصل هشتم

- الگوریتم‌های برخط باید بدون آگاهی از رخدادهای آینده و به صورت آنی تصمیم‌گیری کنند.
- نسبت رقابتی عملکرد الگوریتم برخط را با سناریوی بهینه آفلاین مقایسه می‌نماید.
- الگوریتم حریصانه نسبت رقابتی 50% و الگوریتم BALANCE نسبت رقابتی $63/2\%$ ($1 - 1/e$) را تضمین می‌کنند.
- سیستم AdWords با ترکیب پیشنهادها، کسری بودجه، نرخ کلیک و حراج قیمت دوم، پایداری اقتصادی موتورهای جستجو را رقم می‌زند.