

مبانی و الگوریتم‌های کلان‌داده

جزوه جامع درسی و مرجع دانشگاهی تحلیل کلان‌داده

بر اساس سرفصل‌ها و اسلایدهای کتاب (MMDS) Datasets Massive of Mining
تألیف: ژوره لسکوک، آناند راجارامان، جفری اولمن

گردآورنده: احسان شهبازی

مجموعه یادداشتهای آموزشی کارشناسی ارشد

۷ مهر ۱۴۰۵

فصل ۱۲

یادگیری ماشین در مقیاس بزرگ (Large-Scale Machine Learning)

۱.۱۲ مقدمه و چالش‌های یادگیری ماشین در کلان‌داده

در کاربردهای سنتی یادگیری ماشین، معمولاً با مجموعه داده‌هایی با اندازه متوسط روبرو هستیم که به راحتی در حافظه اصلی یک کامپیوتر بارگذاری می‌شوند. در این شرایط، مدل‌های پیچیده غیرخطی با زمان‌های آموزش چندساعته قابل استفاده هستند. اما در مسائل کلان‌داده، شرایط به کلی دگرگون می‌شود:

- تعداد نمونه‌های آموزشی (N) در مقیاس صدها میلیون یا میلیاردها رکورد است.
- تعداد ابعاد و ویژگی‌ها (d) ممکن است به میلیون‌ها برسد (مانند پیش‌بینی کلیک در تبلیغات یا فیلترینگ هرزنامه).
- الگوریتم‌های با مرتبه زمانی $O(N^2)$ یا $O(N^3)$ (نظیر روش‌های کرنلی سنتی در SVM) عملاً غیرقابل استفاده هستند.
- **قانون طلایی یادگیری ماشین در مقیاس بزرگ:** الگوریتم آموزش باید دارای مرتبه زمانی خطی $O(N)$ باشد و ترجیحاً بتواند با تنها یک گذر (یا تعداد بسیار معدودی گذر) از روی داده‌ها همگرا شود.

۲.۱۲ روش نزدیک‌ترین همسایه در مقیاس بزرگ (k -NN)

در روش نزدیک‌ترین همسایه^۱، هیچ مرحله آموزش اولیه‌ای وجود ندارد (یادگیری تنبل^۲). برای طبقه‌بندی یک نقطه جدید x :

۱. k نقطه از داده‌های آموزشی که کمترین فاصله را تا x دارند پیدا می‌شوند.

۲. برچسب x با رأی اکثریت این k همسایه تعیین می‌گردد.

چالش در کلان‌داده: جستجوی خطی در میان میلیاردها نقطه آموزشی برای هر پرس‌وجو به شدت کند است. راهکار: بهره‌گیری از تکنیک‌های فصل سوم، به‌ویژه **درهم‌سازی حساس به مکان (LSH)** به عنوان یک شاخص پیشرفته؛ بدین ترتیب، بدون نیاز به مقایسه با تمام نقاط، نزدیک‌ترین همسایه‌ها در زمان زیرخطی $O(\log N)$ یا حتی زمان ثابت $O(1)$ بازیابی می‌شوند.

۳.۱۲ طبقه‌بندی خطی و الگوریتم پرسپترون (Perceptron)

در طبقه‌بندی دودویی، داده‌ها به صورت جفت‌های (x_i, y_i) داده شده‌اند که در آن $x_i \in \mathbb{R}^d$ بردار ویژگی و $y_i \in \{-1, +1\}$ برچسب کلاس است. هدف، یافتن یک ابرصفحه جداکننده^۳ است:

$$f(x) = \text{sign}(w \cdot x + b) \quad (1.12)$$

که در آن w بردار وزن‌ها و b مقدار انحراف (بایاس) است.

^۱ k -Nearest Neighbors (k -NN)

^۲ Lazy Learning

^۳ Separating Hyperplane

الگوریتم ۱.۱۲: الگوریتم پرسپترون

۱. بردار وزن را صفر قرار دهید: $w = 0$ و $b = 0$.

۲. داده‌های آموزشی را به صورت متوالی پیمایش کنید. برای هر نمونه (x_i, y_i) :

• مقدار پیش‌بینی را محاسبه کنید: $\hat{y} = \text{sign}(w \cdot x_i + b)$.

• اگر پیش‌بینی اشتباه بود ($y_i(w \cdot x_i + b) \leq 0$):

$$w \leftarrow w + \eta \cdot y_i \cdot x_i \quad (2.12)$$

$$b \leftarrow b + \eta \cdot y_i \quad (3.12)$$

(که در آن $\eta > 0$ نرخ یادگیری است).

۳. تکرار تا زمان همگرایی کامل یا رسیدن به سقف تکرارها.

قضیه ۱.۱۲: قضیه همگرایی پرسپترون (نوویکف)

اگر داده‌ها به صورت خطی تفکیک‌پذیر^a باشند، یعنی ابرصفحه‌ای با حاشیه اطمینان $\gamma > 0$ وجود داشته باشد به طوری که $y_i(w^* \cdot x_i) \geq \gamma$ به ازای $\|w^*\| = 1$ ، آنگاه الگوریتم پرسپترون حداکثر پس از:

$$M \leq \left(\frac{R}{\gamma} \right)^2 \quad (4.12)$$


خطا همگرا می‌شود، که در آن $R = \max_i \|x_i\|$ شعاع کوچک‌ترین کره دربرگیرنده داده‌ها است.

Linearly Separable^a

اما اگر داده‌ها خطی تفکیک‌پذیر نباشند، پرسپترون هرگز همگرا نشده و تا ابد دچار نوسان می‌شود.

۴.۱۲ ماشین‌های بردار پشتیبان در مقیاس بزرگ (SVM)

ماشین بردار پشتیبان^f نه تنها به دنبال یک ابرصفحه جداکننده است، بلکه بهترین و مطمئن‌ترین ابرصفحه را جستجو می‌کند؛ یعنی ابرصفحه‌ای که بیشترین فاصله حاشیه^g را از نزدیک‌ترین نقاط داده‌های آموزشی داشته باشد (شکل ۱.۱۲).



شکل ۱.۱۲: ابرصفحه با حاشیه بیشینه در ماشین‌های بردار پشتیبان (SVM)

فاصله حاشیه هندسی برابر با $\frac{2}{\|w\|}$ است. بنابراین، بیشینه‌سازی حاشیه معادل است با کمینه‌سازی $\|w\|^2$.

۱.۴.۱۲ فرم نرم حاشیه و تابع هزینه لولا (Hinge Loss)

در مسائل واقعی کلان‌داده، داده‌ها نویزی هستند و تفکیک‌پذیری کامل خطی ناممکن است. با تعریف متغیرهای لغزش^۶ $\xi_i \geq 0$ ، به داده‌ها اجازه نقض حاشیه با پرداخت جریمه داده می‌شود:

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \quad \text{شرط} \quad y_i(w \cdot x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \quad (۵.۱۲)$$

مقدار بهینه متغیر لغزش دقیقاً برابر با تابع هزینه لولا^۷ است:

$$\xi_i = \max(0, 1 - y_i(w \cdot x_i + b)) \quad (۶.۱۲)$$

بدین ترتیب، مسئله مقید SVM به یک مسئله بهینه‌سازی نامقید با تابع هدف منظم‌شده تبدیل می‌گردد:

$$\min_{w, b} \mathcal{L}(w, b) = \frac{\lambda}{2} \|w\|^2 + \frac{1}{N} \sum_{i=1}^N \max(0, 1 - y_i(w \cdot x_i + b)) \quad (۷.۱۲)$$

که در آن $\lambda = \frac{1}{C \cdot N}$ ضریب منظم‌سازی است.

۵.۱۲ بهینه‌سازی در مقیاس بزرگ با گرادینان کاهش‌ی تصادفی (SGD)

الگوریتم گرادینان کاهش‌ی استاندارد (Batch Gradient Descent) در هر گام نیازمند محاسبه گرادینان روی تک‌تک N نمونه آموزشی است که برای $N = 10^9$ کاملاً غیرممکن است. در مقابل، گرادینان کاهش‌ی تصادفی^۸ در هر گام تنها یک نمونه تصادفی را بررسی کرده و وزن‌ها را فوراً به‌روزرسانی می‌کند.

الگوریتم ۲.۱۲: الگوریتم SGD Pegasos برای آموزش SVM در مقیاس بزرگ

• ورودی: داده‌های آموزشی، پارامتر منظم‌سازی λ ، و تعداد کل گام‌ها T .

• مقداردهی اولیه: $w_1 = 0$.

• حلقه تکرار: برای $t = 1, 2, \dots, T$

۱. یک نمونه تصادفی (x_t, y_t) از میان داده‌ها برگزینید.

۲. نرخ یادگیری در گام جاری را تنظیم کنید: $\eta_t = \frac{1}{\lambda \cdot t}$.

۳. شرط حاشیه را بررسی نمایید:

– حالت اول: نمونه به درستی و خارج از حاشیه قرار دارد ($y_t(w_t \cdot x_t) \geq 1$):

$$w_{t+1} = (1 - \eta_t \lambda) w_t = \left(1 - \frac{1}{t}\right) w_t \quad (۸.۱۲)$$

(تنها انقباض وزنی برای منظم‌سازی اعمال می‌شود).

– حالت دوم: نقض حاشیه یا خطای طبقه‌بندی ($y_t(w_t \cdot x_t) < 1$):

$$w_{t+1/2} = (1 - \eta_t \lambda) w_t + \eta_t y_t x_t \quad (۹.۱۲)$$

۴. تصویرسازی بر روی گوی بهینه (Projection Step): جهت تضمین تثوریک نرخ همگرایی، بردار وزن به درون گوی به شعاع $1/\sqrt{\lambda}$ تصویر می‌شود:

$$w_{t+1} = \min \left(1, \frac{1/\sqrt{\lambda}}{\|w_{t+1/2}\|} \right) w_{t+1/2} \quad (۱۰.۱۲)$$

^۶ Slack Variables

^۷ Hinge Loss

^۸ Stochastic Gradient Descent (SGD)

نکته امتحانی و کلیدی

ویژگی‌های خیره‌کننده SGD برای کلان‌داده:

۱. **استقلال زمان همگرایی از تعداد کل نمونه‌ها:** اثبات شده است که تعداد گام‌های لازم برای رسیدن به خطای ϵ از مرتبه $O(1/\epsilon)$ است و هیچ وابستگی به اندازه کل مجموعه داده N ندارد!
۲. **آموزش در یک گذر (Streaming ML):** داده‌ها می‌توانند به صورت جریانی مستقیماً از روی دیسک یا شبکه خوانده شوند؛ هر نمونه پس از یک بار به‌روزرسانی دور ریخته می‌شود، بدون آنکه نیازی به ذخیره مجدد آن باشد.

۶.۱۲ موازی‌سازی یادگیری ماشین در نگاشت-کاهش

برای توزیع آموزش مدل‌های یادگیری بر روی خوشه‌های چند هزار ماشینی:

- داده‌ها میان M مپر تقسیم می‌شوند.
- هر مپر یک مدل مجزا یا گرادیان‌های محلی بر روی بسته خود (Mini-batch) را محاسبه می‌کند.
- در مرحله کاهش، وزن‌ها یا گرادیان‌ها تجمیع شده و میانگین آن‌ها گرفته می‌شود (الگوریتم Server Parameter AllReduce). یا

جمع‌بندی فصل دوازدهم

- یادگیری ماشین در کلان‌داده نیازمند الگوریتم‌های با پیچیدگی خطی و کمترین تعداد گذر از روی دیسک است.
- تکنیک LSH اجرای سریع روش NN_k را در ابعاد بالا ممکن می‌سازد.
- الگوریتم پرسپترون با تفکیک‌پذیری خطی همگرا می‌شود اما در صورت وجود نویز دچار ناپایداری است.
- ماشین بردار پشتیبان با پیشینه‌سازی حاشیه و استفاده از تابع هزینه لولا، طبقه‌بندی مقاومی ارائه می‌دهد.
- الگوریتم SGD امکان آموزش برخط مدل‌های خطی را در مقیاس میلیاردها نمونه با مرتبه زمانی مستقل از N میسر می‌سازد.