

مبانی و الگوریتم‌های کلان‌داده

جزوه جامع درسی و مرجع دانشگاهی تحلیل کلان‌داده

بر اساس سرفصل‌ها و اسلایدهای کتاب (MMDS) Datasets Massive of Mining
تألیف: ژوره لسکوک، آناند راجارامان، جفری اولمن

گردآورنده: احسان شهبازی

مجموعه یادداشتهای آموزشی کارشناسی ارشد

۷ مهر ۱۴۰۵

پیش‌گفتار: کلان‌داده و مبانی محاسبات مقیاس‌پذیر

مقدمه و انگیزه

در دهه‌های اخیر، با رشد تصاعدی وب، شبکه‌های اجتماعی، حسگرهای اینترنت اشیا^۱، معاملات مالی و سامانه‌های پایش علمی، جوامع بشری وارد عصری شده‌اند که حجم و سرعت تولید داده‌ها از توان تحلیلی و ذخیره‌سازی ابزارهای سنتی پایگاه داده فراتر رفته است. این پدیده تحت عنوان **کلان‌داده**^۲ شناخته می‌شود. مواجهه با کلان‌داده صرفاً یک مسئله ارتقای سخت‌افزاری نیست؛ بلکه نیازمند بازنگری بنیادین در نظریه الگوریتم‌ها، مدل‌های ریاضی و معماری سیستم‌های محاسباتی است. الگوریتم‌هایی که دارای مرتبه زمانی درجه دوم ($O(n^2)$) یا حتی درجه اول خطی همراه با دسترسی تصادفی به حافظه هستند، بر روی کلان‌داده‌هایی با مقیاس ترابایت و پتابایت عملاً ناکارآمد بوده و متوقف می‌شوند. از این رو، چارچوب نظری جدیدی لازم است که الگوریتم‌های زیرخطی^۳، الگوریتم‌های برخط جریانی^۴، روش‌های تصادفی‌سازی و تقریب^۵، و پردازش موازی و توزیع‌شده^۶ را در کانون توجه قرار دهد.

مرجع اصلی و رویکرد آموزشی این اثر

این کتاب و مجموعه یادداشت‌های جامع درسی بر پایه سرفصل‌های رسمی دوره کارشناسی ارشد مهندسی کامپیوتر و علم داده و با تکیه بر مرجع پیشگام و معتبر دانشگاه استنفورد، یعنی کتاب:

[۱۰] (MMDS) Datasets Massive of Mining

Ullman D. Jeffrey Rajaraman, Anand Leskovec, Jure

تدوین شده است. در تدوین این مجموعه، اصول آموزشی زیر به عنوان راهنمای عمل مد نظر قرار گرفته‌اند:

۱. **محوریت اسلایدهای درسی در ساختار و جهت‌گیری:** ساختار هر فصل، تقدم و تاخر مباحث و میزان تاکید بر مفاهیم دقیقاً منطبق بر اسلایدهای رسمی درس تنظیم شده است تا دانشجویان پیوستگی کاملی میان جلسات درس و متن مکتوب احساس کنند.

۲. **جامعیت و خودپسندگی با بهره‌گیری از متن مرجع:** اسلایدهای درسی به دلیل ماهیت ارائه شفاهی، غالباً موجز و حاوی نکات کلیدی هستند. در این اثر، با رجوع دقیق به متن کتاب مرجع، کلیه تعاریف ریاضی، اثبات‌های راهگشا، تحلیل پیچیدگی الگوریتم‌ها و مثال‌های عددی گام‌به‌گام تشریح شده‌اند به گونه‌ای که مطالعه این کتاب بی‌نیاز از بازخوانی مدام اسلایدها باشد.

۳. **نگارش دانشگاهی و اصطلاح‌شناسی دقیق:** متن با نگارش علمی، روان و استاندارد فارسی نگاشته شده و برای تمامی اصطلاحات تخصصی، در اولین کاربرد، معادل انگلیسی آن‌ها در پاورقی ذکر شده است تا هم غنای علمی زبان فارسی حفظ شود و هم ارتباط دانشجویان با مقالات و ادبیات بین‌المللی گسسته نگردد.

۴. **تمرکز بر بینش شهودی و محاسبات واقعی:** ریاضیات و فرمول‌ها هرگز بدون توضیح شهودی رها نشده‌اند؛ برای هر رابطه ریاضی، معنای هر متغیر، دلیل بهره‌گیری از فرمول و چگونگی تفسیر نتایج تشریح گردیده است.

^۱ Internet of Things (IoT)

^۲ Big Data

^۳ Sublinear Algorithms

^۴ Streaming Algorithms

^۵ Randomized and Approximation Algorithms

^۶ Distributed and Parallel Computing

نقشه راه فصول کتاب

محتوای این اثر در سیزده فصل اصلی و بر اساس یک جریان منطقی منسجم به شرح زیر سازمان‌دهی شده است:

- **فصل ۱: داده‌کاوی و فضاهای با بعد بالا** – بررسی ماهیت داده‌کاوی، مقایسه رویکرد یادگیری ماشین در برابر مدل‌های آماری، اصل بونفرونی^۷ و اجتناب از کشف الگوهای کاذب، و چالش‌های محاسباتی در فضاهای ابعادی بزرگ.
- **فصل ۲: نگاشت-کاهش و پشته نرم‌افزاری** – معماری سیستم‌های فایل توزیع‌شده (مانند HDFS)، مدل برنامه‌نویسی نگاشت-کاهش^۸، شیوه‌های مدیریت خطا، و پیاده‌سازی عملیات ماتریسی و جبر رابطه‌ای در مقیاس وسیع.
- **فصل ۳: یافتن آیتم‌های مشابه** – مسئله مقایسه اسناد در وب، روش شینگلینگ^۹، معیار تشابه جاکارد^{۱۰}، تکنیک Min-Hashing، و درهم‌سازی حساس به مکان^{۱۱} جهت کاهش ابعاد جستجو.
- **فصل ۴: کاوش جریان‌های داده** – مدل محاسباتی جریان داده، نمونه‌گیری مخزنی^{۱۲}، فیلترهای بلوم^{۱۳}، تخمین تعداد اعضای متمایز با الگوریتم فلزوله-مارتین^{۱۴}، و شمارش بیت‌های یک در پنجره لغزان با الگوریتم DGIM.
- **فصل ۵: تحلیل پیوندها و رتبه‌بندی وب** – ساختار گراف وب، الگوریتم مشهور رتبه‌بندی صفحه^{۱۵}، تله‌های عنکبوتی و بن‌بست‌ها، راهکار بازآغازی تصادفی، رتبه‌بندی وابسته به موضوع، و الگوریتم HITS.
- **فصل ۶: مجموعه‌آیتم‌های پرتکرار** – مدل سبد بازار^{۱۶}، قوانین انجمنی^{۱۷}، الگوریتم A-Priori و بهینه‌سازی‌های حافظه‌محور نظیر PCY و Multistage، و الگوریتم‌های توزیع‌شده SON و Toivonen.
- **فصل ۷: خوشه‌بندی در ابعاد بالا** – محدودیت‌های روش‌های خوشه‌بندی سنتی در ابعاد بالا، الگوریتم‌های سلسله‌مراتبی، K-Means و بهینه‌سازی‌های BFR و CURE برای خوشه‌بندی داده‌های عظیم با شکل‌های پیچیده.
- **فصل ۸: تبلیغات برخط در وب** – مدل تطابق دوبخشی برخط^{۱۸}، نسبت رقابتی^{۱۹}، الگوریتم BALANCE و سازوکار حراج آگهی گوگل (AdWords).
- **فصل ۹: سامانه‌های توصیه‌گر** – ماتریس سودمندی^{۲۰}، فیلترینگ محتوا محور، فیلترینگ مشارکتی^{۲۱}، و تجزیه ماتریسی با کاهش مقدار منفرد (SVD) و فاکتورسازی ماتریس UV.
- **فصل ۱۰: کاوش گراف‌های شبکه‌های اجتماعی** – ساختار جوامع در شبکه‌های اجتماعی، مرکزیت بینابینی و الگوریتم گیروان-نیومن^{۲۲}، معیار پیمانه‌ای^{۲۳}، و خوشه‌بندی طیفی^{۲۴} با ماتریس لاپلاسی.
- **فصل ۱۱: کاهش بعد** – تجزیه مقادیر منفرد^{۲۵}، تحلیل مؤلفه‌های اصلی^{۲۶}، لم جانسون-لیندن‌اشترواس^{۲۷}، و تجزیه ماتریسی CUR.

-
- Bonferroni's Principle^۷
 - MapReduce^۸
 - Shingling^۹
 - Jaccard Similarity^{۱۰}
 - Locality-Sensitive Hashing (LSH)^{۱۱}
 - Reservoir Sampling^{۱۲}
 - Bloom Filters^{۱۳}
 - Flajolet-Martin Algorithm^{۱۴}
 - PageRank^{۱۵}
 - Market-Basket Model^{۱۶}
 - Association Rules^{۱۷}
 - Online Bipartite Matching^{۱۸}
 - Competitive Ratio^{۱۹}
 - Utility Matrix^{۲۰}
 - Collaborative Filtering^{۲۱}
 - Girvan-Newman Algorithm^{۲۲}
 - Modularity^{۲۳}
 - Spectral Clustering^{۲۴}
 - Singular Value Decomposition (SVD)^{۲۵}
 - Principal Component Analysis (PCA)^{۲۶}
 - Johnson-Lindenstrauss Lemma^{۲۷}

- **فصل ۱۲: یادگیری ماشین در مقیاس بزرگ** – ماشین‌های بردار پشتیبان^{۲۸}، تابع هزینه لولا^{۲۹}، گرادیان کاهشی تصادفی^{۳۰} با یک گذر، و موازی‌سازی الگوریتم‌های یادگیری.
- **فصل ۱۳: شبکه‌های عصبی و یادگیری عمیق** – پرسپترون چندلایه، پس‌انتشار خطا^{۳۱}، شبکه‌های پیچشی (CNN) و ساختارهای توجه و ترنسفورمرها در کلان‌داده و پردازش‌های توزیع‌شده GPU.

راهنمای مطالعه و آمادگی برای آزمون

برای بهره‌گیری حداکثری از این کتاب توصیه می‌شود:

۱. در ابتدای هر فصل، بخش «مقدمه و اهداف فصل» را مرور فرمایید تا نقشه مفهومی مبحث در ذهن شکل گیرد.
۲. به کادرهای مشخص‌شده با رنگ‌های مختلف توجه فرمایید:
 - کادرهای **آبی** بیانگر تعاریف پایه و اصطلاحات رسمی هستند.
 - کادرهای **سبز** قضایا، لم‌ها و گزاره‌های ریاضی اثبات‌شده هستند.
 - کادرهای **خاکستری** مشخصات گام‌به‌گام و شبه‌کد الگوریتم‌ها هستند.
 - کادرهای **نارنجی** مثال‌های عددی حل‌شده را در بر دارند.
 - کادرهای **قرمز** حاوی نکات طلایی امتحانی و دام‌های متداول مفهومی می‌باشند.
۳. مثال‌های عددی را به صورت دستی روی کاغذ دنبال کنید تا مهارت لازم در آزمون‌ها و تمرین‌های عملی حاصل گردد.

شناسنامه علمی و عوامل تدوین اثر

- **عنوان کتاب:** مبانی و الگوریتم‌های کلان‌داده (Mining of Massive Datasets)
- **گردآورنده و پژوهشگر:** احسان شهبازی (Ehsan Shahbazi)
- **پست الکترونیک:** ehsan.shahbazipc@gmail.com
- **مخزن و صفحه رسمی گیت‌هاب:** github.com/EhsanShahbazi
- **مرجع درسی:** کتاب Mining of Massive Datasets، دانشگاه استنفورد
- **مقطع و جامعه مخاطب:** دانشجویان تحصیلات تکمیلی مهندسی کامپیوتر، هوش مصنوعی و علم داده

^{۲۸} Support Vector Machines (SVM)
^{۲۹} Hinge Loss
^{۳۰} Stochastic Gradient Descent (SGD)
^{۳۱} Backpropagation