

مبانی و الگوریتم‌های کلان‌داده

جزوه جامع درسی و مرجع دانشگاهی تحلیل کلان‌داده

بر اساس سرفصل‌ها و اسلایدهای کتاب (MMDS) Datasets Massive of Mining
تألیف: ژوره لسکوک، آناند راجارامان، جفری اولمن

گردآورنده: احسان شهبازی

مجموعه یادداشتهای آموزشی کارشناسی ارشد

۷ مهر ۱۴۰۵

فصل ۳

یافتن آیتم‌های مشابه و درهم‌سازی حساس به مکان (LSH)

۱.۳ مقدمه و تعریف مسئله

در تحلیل کلان‌داده، یکی از متداول‌ترین نیازمندی‌ها، یافتن آیتم‌هایی است که به یکدیگر «مشابه» هستند. کاربردهای این مسئله بسیار متنوع و گسترده است:


- **تشخیص اسناد تکراری یا تقریباً یکسان^۱:** شناسایی صفحات آینه‌ای در وب، سرقت ادبی در مقالات، یا اخبار بازنشر شده از یک خبرگزاری در سایت‌های مختلف.
 - **سامانه‌های توصیه‌گر^۲:** یافتن کاربرانی که سلیقه یا تاریخچه خرید یکسانی در فروشگاه آنلاین دارند.
 - **جستجوی تصاویر مشابه:** بازیابی تصاویری که علیرغم تغییرات اندک در رزولوشن یا کادربندی، محتوای یکسانی دارند.
 - **شناسایی کلاهبرداری^۳:** یافتن گزارش‌های پزشکی یا خسارت‌های بیمه‌ای با شرح یکسان.
- اگر مجموعه‌ای شامل N آیتم داشته باشیم، مقایسه دوجه‌دوی تمامی جفت‌ها نیازمند انجام:

$$\binom{N}{2} = \frac{N(N-1)}{2} \approx \frac{N^2}{2} \quad (1.3)$$

مقایسه است. چنانچه $N = 10^6$ (یک میلیون سند) باشد، تعداد مقایسه‌ها حدود 5×10^{11} خواهد بود. حتی اگر هر مقایسه تنها ۱ میکروثانیه زمان ببرد، اجرای آن نزدیک به ۶ روز به طول می‌انجامد؛ برای $N = 10^7$ ، این زمان به ۶۰۰ روز افزایش خواهد یافت!

برای حل این چالش بنیادین، یک خط لوله محاسباتی سه‌مرحله‌ای طراحی شده است (شکل ۱.۳):

۱. **شینگلینگ (Shingling):** تبدیل اسناد متنی به مجموعه‌هایی از توکن‌های متوالی کوتاه.
۲. **کمینه‌سازی درهم‌سازی (Min-Hashing):** تبدیل مجموعه‌های بسیار بزرگ به امضاهای کوتاه، به نحوی که تشابه مجموعه‌ها حفظ گردد.
۳. **درهم‌سازی حساس به مکان (LSH):** متمرکز ساختن بررسی‌ها تنها بر روی جفت‌های نامزدی که احتمال شباهت آن‌ها بسیار بالاست، بدون نیاز به مقایسه تمامی جفت‌ها.



شکل ۱.۳: خط لوله استاندارد سه‌مرحله‌ای برای یافتن آیتم‌های مشابه در کلان‌داده

^۱ Near-Duplicate Documents
^۲ Recommender Systems
^۳ Fraud Detection

۲.۳ گام نخست: شینگلینگ اسناد

برای مقایسه دو سند، نمی‌توان صرفاً به برابری دقیق کلمات نگاه کرد، زیرا تغییر ترتیب چند کلمه یا افزودن یک پاراگراف کوتاه نباید مانع از کشف شباهت شود.

تعریف ۱.۳: k -شینگل یا k -گرام

یک k -شینگل^a برای یک سند متنی، هر زیررشته به طول k است که در درون آن سند ظاهر می‌شود. شینگل‌ها می‌توانند بر حسب کاراکتر یا واژه تعریف شوند.

^aShingle- k یا Gram- k

مثال کاربردی ۱.۳: استخراج شینگل‌ها

فرض کنید سند D برابر با رشته «abcdabd» باشد و $k = ۲$ کاراکتر در نظر گرفته شود. مجموعه شینگل‌های موجود در سند عبارت‌اند از:

$$S(D) = \{ab, bc, cd, da, bd\} \quad (۲.۳)$$

توجه نمایید که شینگل «ab» دوبار ظاهر شده است، اما در قالب مجموعه، عناصر تکراری حذف می‌گردند (مگر آنکه از چندمجموعه^a استفاده شود).

^aBag of Shingles

۱.۲.۳ انتخاب اندازه مناسب برای k

- اگر k خیلی کوچک انتخاب شود (مثلاً $k = ۱$ یا $k = ۲$ در زبان انگلیسی)، تقریباً تمام شینگل‌ها در تمام اسناد تکرار خواهند شد؛ در نتیجه همه اسناد به اشتباه شبیه هم ارزیابی می‌شوند.
- قانون تجربی: k باید آن‌قدر بزرگ باشد که احتمال حضور تصادفی یک شینگل خاص در سندی نامرتب بسیار اندک باشد. برای اسناد معمولی متنی (ایمیل‌ها و مقالات کوتاه) معمولاً $k = ۵$ واژه یا $k = ۹$ کاراکتر انتخاب می‌شود.
- **فشرده‌سازی شینگل‌ها:** برای صرفه‌جویی در مصرف حافظه، هر شینگل با استفاده از یک تابع درهم‌سازی مطمئن به یک عدد صحیح ۴ بیتی (۳۲ بیتی) نگاشت می‌شود؛ بدین ترتیب هر سند به مجموعه‌ای از اعداد ۴ بیتی تبدیل می‌گردد.

۳.۳ معیار تشابه جاکارد و ماتریس مشخصه

تعریف ۲.۳: تشابه جاکارد

تشابه جاکارد^a میان دو مجموعه S و T برابر است با نسبت اندازه اشتراک آن‌ها به اندازه اجتماع آن‌ها:

$$\text{SIM}(S, T) = J(S, T) = \frac{|S \cap T|}{|S \cup T|} \quad (۳.۳)$$

فاصله جاکارد^b نیز به صورت مکمل تشابه تعریف می‌شود:

$$d_J(S, T) = 1 - J(S, T) = \frac{|S \cup T| - |S \cap T|}{|S \cup T|} \quad (۴.۳)$$

Jaccard Similarity^aJaccard Distance^b

قضیه ۱.۳: ویژگی متریک فاصله جاکارد

فاصله جاکارد $d_J(S, T) = 1 - J(S, T)$ یک **متریک ریاضی معتبر** است؛ یعنی هر چهار شرط فضای متریک را ارضا می‌کند:

۱. **نامنفی بودن:** $d_J(S, T) \geq 0$ (چون $0 \leq J(S, T) \leq 1$).

۲. **انطباق بر خود:** $d_J(S, T) = 0 \iff S = T$.

۳. **تقارن:** $d_J(S, T) = d_J(T, S)$.

۴. **نامساوی مثلثی:** برای هر سه مجموعه S_1, S_2, S_3 :

$$d_J(S_1, S_3) \leq d_J(S_1, S_2) + d_J(S_2, S_3) \quad (۵.۳)$$

اثبات نامساوی مثلثی با بهره‌گیری از Min-Hashing: بر اساس قضیه Min-Hashing، فاصله جاکارد دقیقاً برابر است با احتمال عدم تطابق مقدار هش تصادفی دو مجموعه:

$$d_J(S, T) = \Pr[h(S) \neq h(T)] \quad (۶.۳)$$

حال برای هر سه مجموعه S_1, S_2, S_3 ، اگر $h(S_1) \neq h(S_3)$ رخ دهد، لزوماً حداقل یکی از دو رویداد $h(S_1) \neq h(S_2)$ یا $h(S_2) \neq h(S_3)$ باید اتفاق افتاده باشد (زیرا اگر هر دو جفت برابر بودند، بنا بر اصل تعدی باید $h(S_1) = h(S_3)$ می‌شد). بنابراین طبق قاعده اجتماع احتمالات:

$$\Pr[h(S_1) \neq h(S_3)] \leq \Pr[h(S_1) \neq h(S_2)] + \Pr[h(S_2) \neq h(S_3)] \quad (۷.۳)$$

که مستقیماً نامساوی مثلثی $d_J(S_1, S_3) \leq d_J(S_1, S_2) + d_J(S_2, S_3)$ را به اثبات می‌رساند.

۱.۳.۳ ماتریس مشخصه (Characteristic Matrix)

اگر تمام شینگل‌های جهان داده را به عنوان سطرهای یک ماتریس و اسناد مختلف را به عنوان ستون‌های آن در نظر بگیریم، **ماتریس مشخصه**^۴ حاصل می‌شود:

$$M_{ij} = \begin{cases} 1 & \text{وجود داشته باشد } j \text{ در سند } i \text{ اگر شینگل} \\ 0 & \text{در غیر این صورت} \end{cases} \quad (۸.۳)$$

این ماتریس در عمل بی‌نهایت تنگ^۵ است و هرگز به طور کامل در حافظه ذخیره نمی‌شود، اما چارچوب مفهومی بسیار روشنی برای تعریف Min-Hashing فراهم می‌آورد.

Characteristic Matrix^۴
Sparse^۵

۴.۳ گام دوم: کمینه‌سازی درهم‌سازی (Min-Hashing)

هدف از Min-Hashing فشرده‌سازی ستون‌های بسیار طولانی ماتریس مشخصه به بردارها و امضاهای کوتاه با طول n (مثلاً $n = 100$ یا 200) است، به گونه‌ای که تشابه امضاها دقیقاً برابر با تشابه جاکارد مجموعه‌های اصلی باشد.

۱.۴.۳ جایگشت سطرها و تابع Min-Hash

فرض کنید جایگشتی تصادفی π بر روی سطرهای ماتریس مشخصه اعمال کنیم.

تعریف ۳.۳: تابع Min-Hash

مقدار $h_{\pi}(C)$ برای ستون C برابر است با شماره نخستین سطر (در ترتیب جایگشت π) که مقدار درایه ستون C در آن سطر برابر با ۱ باشد.

قضیه ۲.۳: قضیه بنیادین Min-Hashing []

احتمال اینکه مقدار Min-Hash دو ستون C_1 و C_2 با یکدیگر برابر باشد، دقیقاً معادل تشابه جاکارد آن دو ستون است:

$$\Pr[h_{\pi}(C_1) = h_{\pi}(C_2)] = \text{SIM}(C_1, C_2) = J(C_1, C_2) \quad (9.3)$$

اثبات قضیه: سطرهای ماتریس مشخصه نسبت به دو ستون C_1 و C_2 به سه دسته تقسیم می‌شوند:

- نوع X : سطرهایی که در هر دو ستون مقدار ۱ دارند (تعداد: $|C_1 \cap C_2|$). $x = |C_1 \cap C_2|$.
- نوع Y : سطرهایی که در یکی از دو ستون مقدار ۱ و در دیگری ۰ دارند (تعداد: $|C_1 \cup C_2| - |C_1 \cap C_2|$). $y = |C_1 \cup C_2| - |C_1 \cap C_2|$.
- نوع Z : سطرهایی که در هر دو ستون مقدار ۰ دارند.

هنگامی که سطرها را به صورت تصادفی جایگشت می‌دهیم و از بالا به پایین پیمایش می‌کنیم، سطرهای نوع Z تاثیری در مقدار Min-Hash ندارند زیرا مقدار هر دو ستون صفر است. بنابراین، نخستین سطر که مقدار ۱ در آن دیده می‌شود، یا از نوع X خواهد بود یا از نوع Y . مقدار $h_{\pi}(C_1) = h_{\pi}(C_2)$ خواهد بود اگر و تنها اگر نخستین سطر غیرصفر مشاهده‌شده از نوع X باشد. احتمال این رخداد برابر است با نسبت تعداد سطرهای نوع X به کل سطرهای نوع X و Y :

$$\Pr[h_{\pi}(C_1) = h_{\pi}(C_2)] = \frac{x}{x+y} = \frac{|C_1 \cap C_2|}{|C_1 \cup C_2|} = J(C_1, C_2) \quad (10.3)$$

و حکم اثبات می‌شود.

۲.۴.۳ الگوریتم شبیه‌سازی Min-Hash بدون اعمال جایگشت فیزیکی

در کلان‌داده، جایگشت دادن فیزیکی میلیاردها سطر ناممکن است. به جای آن، از n تابع درهم‌سازی مستقل به فرم $h_i(r) = (a_i r + b_i) \pmod{p}$ استفاده می‌شود. الگوریتم ماتریس امضا به شرح زیر عمل می‌کند:

الگوریتم ۱.۳: محاسبه ماتریس امضای Min-Hash

- ورودی: ماتریس مشخصه با R سطر و C ستون، و n تابع درهم‌سازی $h_1, h_2, \dots, h_n$.
- خروجی: ماتریس امضا SIG با ابعاد $n \times C$.
- مقداردهی اولیه: برای تمامی درایه‌های ماتریس امضا، $SIG(i, c) = \infty$ قرار دهید.
- پیمایش سطر به سطر: به ازای هر سطر r از ماتریس مشخصه:
 ۱. مقادیر $h_1(r), h_2(r), \dots, h_n(r)$ را محاسبه کنید.

۲. به ازای هر ستون c که در آن سطر مقدار ۱ دارد:

$$SIG(i, c) = \min(SIG(i, c), h_i(r)) \quad \forall i \in \{1, \dots, n\} \quad (11.3)$$


۵.۳ گام سوم: درهم‌سازی حساس به مکان (LSH) برای امضاها

حتی پس از تبدیل اسناد به امضاها، اگر بخواهیم تمامی جفت‌امضاها را با یکدیگر مقایسه کنیم، همچنان با هزینه زمانی مرتبه $O(N^2)$ روبرو هستیم. روش LSH^۶ راهکاری هوشمندانه برای کاهش فضای جستجو است.

۱.۵.۳ روش دسته‌بندی نواری (Banding Technique)

فرض کنید ماتریس امضا دارای n سطر است. این ماتریس را به b نوار^۷ تقسیم می‌کنیم، به طوری که هر نوار شامل دقیقاً r سطر متوالی باشد، یعنی:

$$n = b \times r \quad (12.3)$$



شکل ۲.۳: افراز ماتریس امضا به b نوار از r سطر و هش کردن بخش‌های ستون به سطل‌ها

سازوکار الگوریتم به شرح زیر است:

۱. برای هر نوار، یک تابع درهم‌سازی مجزا در نظر می‌گیریم.
۲. قطعه r -عنصری هر ستون در آن نوار را به یکی از سطل‌های متعدد درهم‌سازی نگاشت می‌کنیم.
۳. **قاعده جفت‌های نامزد:** دو سند C_1 و C_2 به عنوان **جفت نامزد**^۸ اعلام می‌شوند اگر و تنها اگر حداقل در یک نوار، در سطل یکسانی قرار گیرند.
۴. تنها جفت‌های نامزد مورد مقایسه کامل شباهت قرار می‌گیرند.

۲.۵.۳ تحلیل ریاضی منحنی اس-شکل (S-Curve Analysis)

فرض کنید تشابه واقعی جاکارد میان دو سند برابر با $s = J(C_1, C_2)$ باشد. می‌خواهیم احتمال نامزد شدن این دو سند $(f(s))$ را محاسبه نماییم:

۱. احتمال اینکه دو ستون در یک سطر خاص از یک نوار توافق داشته باشند: s .
۲. احتمال اینکه در تمام r سطر یک نوار خاص توافق داشته باشند (یعنی در آن نوار در یک سطل بیفتند):

$$P(\text{تطابق در نوار خاص}) = s^r \quad (13.3)$$

^۶ Locality-Sensitive Hashing
^۷ Band
^۸ Candidate Pair

۳. احتمال اینکه در آن نوار خاص تطابق نداشته باشند:

$$1 - s^r \quad (۱۴.۳)$$

۴. احتمال اینکه در هیچ‌یک از b نوار تطابق نداشته باشند (عدم توافق در تمام نوارها):

$$(1 - s^r)^b \quad (۱۵.۳)$$

۵. بنابراین، احتمال اینکه در حداقل یک نوار تطابق داشته باشند (شرط نامزدی):

$$f(s) = 1 - (1 - s^r)^b \quad (۱۶.۳)$$

نمودار تابع $f(s)$ دارای شکل S است. آستانه شباهت بحرانی s^* که در آن شیب منحنی بیشترین مقدار است، با تقریب عالی از رابطه زیر به دست می‌آید:

$$s^* \approx \left(\frac{1}{b}\right)^{1/r} \quad (۱۷.۳)$$

اگر تشابه دو سند $s > s^*$ باشد، احتمال نامزدی آنها به سرعت به ۱ نزدیک می‌شود؛ و اگر $s < s^*$ باشد، احتمال نامزدی به سرعت به ۰ میل می‌کند.

مثال کاربردی ۲.۳: محاسبه احتمال خطای مثبت کاذب و منفی کاذب در LSH

فرض کنید $n = ۱۰۰$ سطر در ماتریس امضا داریم و آن را به $b = ۲۰$ نوار با $r = ۵$ سطر تقسیم کرده‌ایم. آستانه تقریب برابر است با:

$$s^* \approx (1/20)^{1/5} \approx 0.549 \quad (۱۸.۳)$$

حال دو سناریو را بررسی می‌کنیم:

• دو سند با شباهت بالا $s = 0.8$:

$$f(0.8) = 1 - (1 - 0.8^5)^{20} = 1 - (1 - 0.32768)^{20} = 1 - (0.67232)^{20} \approx 1 - 0.00035 = 0.99965 \quad (۱۹.۳)$$

یعنی با احتمال ۹۹/۹۶۵٪ این دو سند به درستی شناسایی می‌شوند (تنها ۰/۰۳۵٪ خطای منفی کاذب).

• دو سند با شباهت پایین $s = 0.2$:

$$f(0.2) = 1 - (1 - 0.2^5)^{20} = 1 - (1 - 0.00032)^{20} \approx 1 - (1 - 20 \times 0.00032) \approx 0.0064 \quad (۲۰.۳)$$

احتمال اینکه این دو سند نامزد شوند کمتر از ۰/۶۴٪ است (خطای مثبت کاذب بسیار اندک).

۶.۳ معیارهای فاصله و خانواده‌های درهم‌سازی حساس به مکان

تشابه جاکارد تنها یکی از معیارهای فاصله است. در کلان‌داده، انواع معیارهای فاصله به کار می‌روند:

تعریف ۴.۳: اصول موضوعه یک تابع فاصله (متریک)

یک تابع $d(x, y)$ یک متریک معتبر است اگر و تنها اگر در چهار شرط زیر صدق کند:

۱. نامنفی بودن: $d(x, y) \geq 0$.

۲. تفکیک‌پذیری: $d(x, y) = 0 \iff x = y$.

۳. تقارن: $d(x, y) = d(y, x)$.

۴. نامساوی مثلثی: $d(x, z) \leq d(x, y) + d(y, z)$.

- **فاصله اقلیدسی** (L_2) : $d(x, y) = \sqrt{\sum_i (x_i - y_i)^2}$.
- **فاصله منهتن** (L_1) : $d(x, y) = \sum_i |x_i - y_i|$.
- **فاصله کسینوسی**: زاویه بین دو بردار، $\theta = \arccos\left(\frac{x \cdot y}{\|x\| \|y\|}\right)$ ، که منجر به روش اَبَرَبَرش‌های تصادفی^{۱۰} یا SimHash می‌شود.
- **فاصله همینگ**^{۱۱}: تعداد موقعیت‌هایی که دو رشته با طول برابر در آن‌ها متفاوت‌اند.

نکته امتحانی و کلیدی

- در آزمون‌ها، نحوه تنظیم پارامترهای b و r با توجه به آستانه مورد نظر s بسیار حائز اهمیت است:
- اگر هدف کاهش **منفی کاذب**^a باشد (نمی‌خواهیم هیچ جفت مشابهی جا بیفتد)، b را افزایش و r را کاهش می‌دهیم (پایین آوردن آستانه).
 - اگر هدف کاهش **مثبت کاذب**^b و کاهش زمان محاسبات باشد، r را افزایش می‌دهیم تا شرط سخت‌گیرانه‌تری برای هم‌سطلی اعمال گردد.

False Negatives^a
False Positives^b

جمع‌بندی فصل سوم

- مقایسه دوبه‌دوی اسناد در کلان‌داده به دلیل مرتبه زمانی $O(N^2)$ غیرممکن است.
- شینگلینگ اسناد را به مجموعه‌هایی مناسب برای ارزیابی تشابه جاکارد تبدیل می‌کند.
- روش Min-Hashing با تکیه بر جایگشت‌های تصادفی، مجموعه‌های حجیم را به امضاهایی کوتاه فشرده می‌سازد به نحوی که $\Pr[h(C_1) = h(C_2)] = J(C_1, C_2)$.
- الگوریتم LSH با تقسیم ماتریس امضا به b نوار از r سطر و ایجاد منحنی، شکل-S فضای جستجو را تنها به نامزدهای بسیار محتمل محدود می‌سازد.