

مبانی و الگوریتم‌های کلان‌داده

جزوه جامع درسی و مرجع دانشگاهی تحلیل کلان‌داده

بر اساس سرفصل‌ها و اسلایدهای کتاب (MMDS) Datasets Massive of Mining
تألیف: ژوره لسکوک، آناند راجارامان، جفری اولمن

گردآورنده: احسان شهبازی

مجموعه یادداشتهای آموزشی کارشناسی ارشد

۷ مهر ۱۴۰۵

فصل ۷

خوشه‌بندی در فضاهای با بعد بالا (High-Dimensional Clustering)

۱.۷ مقدمه و چالش‌های خوشه‌بندی کلان‌داده

خوشه‌بندی^۱ فرآیند افراز مجموعه‌ای از اشیاء یا نقاط داده به گروه‌هایی (خوشه‌ها) است، به گونه‌ای که شباهت میان اعضای درون یک خوشه حداکثر، و شباهت میان اعضای خوشه‌های متمایز حداقل باشد. در مبحث کلان‌داده، خوشه‌بندی با دو چالش بنیادین مواجه است:

۱. **نفرین ابعاد (Curse of Dimensionality)**: با افزایش تعداد ابعاد (مثلاً در فضاهای ۱۰۰۰ بعدی متنی یا ویژگی‌های تصویری):

- تقریباً تمامی جفت‌نقاط دارای فواصل اقلیدسی تقریباً برابری از یکدیگر می‌شوند.
- حجم فضا به صورت نمایی رشد کرده و داده‌ها به شدت تنگ می‌شوند؛ به گونه‌ای که تقریباً تمامی نقاط بر روی پوسته یا مرز فضا قرار می‌گیرند.
- تعاریف سنتی فاصله، کارایی تفکیک‌کنندگی خود را از دست می‌دهند.

۲. **محدودیت حافظه اصلی (RAM Bottleneck)**: مجموعه داده‌ها شامل میلیون‌ها یا میلیارد‌ها نقطه هستند و امکان بارگذاری تمامی نقاط در حافظه برای اجرای الگوریتم‌های تکراری وجود ندارد. داده‌ها باید روی دیسک قرار داشته باشند و الگوریتم تنها با یک یا دو گذر از روی دیسک، خوشه‌ها را شناسایی کند.

روش‌های خوشه‌بندی عموماً به دو دسته کلی تقسیم می‌شوند:

- **روش‌های سلسله‌مراتبی^۲**: ساخت درختی از خوشه‌ها به صورت پایین به بالا یا بالا به پایین.
- **روش‌های تخصیص نقطه^۳**: انتساب هر نقطه به مناسب‌ترین خوشه بر اساس توابع هدف و مراکز خوشه‌ها (نظیر K-Means).

۲.۷ خوشه‌بندی سلسله‌مراتبی تراکمی (Agglomerative)

در این روش، ابتدا هر نقطه داده به عنوان یک خوشه تک‌عضوی در نظر گرفته می‌شود. سپس در هر مرحله، دو خوشه‌ای که کمترین فاصله را دارند با یکدیگر ادغام می‌شوند تا در نهایت تمامی نقاط در یک خوشه واحد تجمیع گردند (یا تعداد خوشه‌ها به k برسد).

۱.۲.۷ معیارهای فاصله میان دو خوشه

تعریف فاصله میان دو خوشه C_1 و C_2 تعیین‌کننده شکل نهایی خوشه‌ها است:

Clustering^۱
Hierarchical Clustering^۲
Point Assignment^۳

• پیوند یگانه (Single Linkage): کمترین فاصله میان اعضا:

$$d(C_1, C_2) = \min_{x \in C_1, y \in C_2} d(x, y) \quad (1.7)$$

تمایل به تولید خوشه‌های کشیده و زنجیره‌ای دارد.

• پیوند کامل (Complete Linkage): بیشترین فاصله میان اعضا:

$$d(C_1, C_2) = \max_{x \in C_1, y \in C_2} d(x, y) \quad (2.7)$$

تمایل به تولید خوشه‌های فشرده و کروی دارد.

• فاصله مراکز (Centroid Distance): فاصله میان میانگین‌های دو خوشه $d(\mu_1, \mu_2)$.

۳.۷ الگوریتم K-Means و نسخه بهینه K-Means++

الگوریتم K-Means یکی از پرکاربردترین روش‌های تخصیص نقطه در فضای اقلیدسی است:

الگوریتم ۱.۷: الگوریتم استاندارد K-Means

• ورودی: مجموعه نقاط X و تعداد خوشه‌ها k .

• گام ۱ (مقداردهی اولیه): k نقطه به عنوان مراکز اولیه خوشه‌ها $(c_1, \dots, c_k)$ انتخاب می‌شوند.

• گام ۲ (تخصیص نقاط): هر نقطه $x \in X$ به نزدیک‌ترین مرکز خوشه تخصیص می‌یابد:

$$\text{Cluster}(x) = \arg \min_{j \in \{1, \dots, k\}} \|x - c_j\|^2 \quad (3.7)$$

• گام ۳ (به‌روزرسانی مراکز): مرکز هر خوشه برابر با میانگین هندسی تمامی نقاط تخصیص‌یافته به آن بازتعریف می‌شود:

$$c_j = \frac{1}{|C_j|} \sum_{x \in C_j} x \quad (4.7)$$

• تکرار: گام‌های ۲ و ۳ تا زمان تثبیت مراکز یا کمترین تغییر در تابع هزینه تکرار می‌شوند.

۱.۳.۷ الگوریتم K-Means++ برای مقداردهی اولیه هوشمند

انتخاب تصادفی ساده مراکز اولیه در K-Means سنتی ممکن است منجر به گیر افتادن در کمینه‌های محلی بسیار ضعیف شود. الگوریتم K-Means++ مراکز را با توزیع احتمال هوشمندانه برمی‌گزیند:

۱. اولین مرکز c_1 به صورت کاملاً تصادفی و یکنواخت از میان نقاط داده انتخاب می‌شود.

۲. برای هر نقطه داده x ، کوتاه‌ترین فاصله آن تا نزدیک‌ترین مرکز انتخاب‌شده قبلی، یعنی $D(x)$ ، محاسبه می‌شود.

۳. مرکز بعدی با احتمالی متناسب با مربع فاصله انتخاب می‌گردد:

$$P(x) = \frac{D(x)^2}{\sum_{y \in X} D(y)^2} \quad (5.7)$$

۴. گام‌های ۲ و ۳ تکرار می‌شوند تا هر k مرکز اولیه انتخاب گردند.

این الگوریتم تضمین اثبات‌شده ریاضی ارائه می‌دهد که امید هزینه خوشه نهایی هرگز از $O(\log k)$ برابر بهینه جهانی تجاوز نمی‌کند.

۴.۷ خوشه‌بندی کلان‌داده در فضای اقلیدسی: الگوریتم BFR

الگوریتم BFR^۴ [۳] نسخه بهینه‌سازی شده K-Means برای کلان‌داده‌هایی است که بسیار فراتر از گنجایش حافظه اصلی هستند.

۱.۴.۷ فرضیات بنیادین BFR

۱. داده‌ها در فضای اقلیدسی تعریف شده‌اند.

۲. خوشه‌ها پیرو توزیع نرمال چندمتغیره حول مرکز هستند و ابعاد داده نسبت به یکدیگر استقلال دارند (ماتریس کوواریانس قطری).

۲.۴.۷ خلاصه‌سازی داده‌ها با آماره‌های سه‌گانه $(N, SUM, SUMSQ)$

برای اینکه نیاز به ذخیره تمامی نقاط در حافظه نباشد، هر خوشه توسط سه بردار خلاصه آماری توصیف می‌شود:

(۶.۷) تعداد نقاط موجود در خوشه : N

$$SUM_i = \sum_{j=1}^N x_{ji} \quad (i \text{مجموع مختصات در بعد}) \quad (۷.۷)$$

$$SUMSQ_i = \sum_{j=1}^N x_{ji}^2 \quad (i \text{مجموع مربع مختصات در بعد}) \quad (۸.۷)$$

از روی این سه آماره، مرکز خوشه c و انحراف معیار σ در هر بعد i بلافاصله قابل استخراج است:

$$c_i = \frac{SUM_i}{N}, \quad \sigma_i = \sqrt{\frac{SUMSQ_i}{N} - c_i^2} \quad (۹.۷)$$

۳.۴.۷ سه مجموعه داده در حافظه اصلی

الگوریتم BFR نقاط بارگذاری شده در حافظه را به سه دسته افراز می‌کند:

- **مجموعه دفع شده (Discard Set - DS):** نقاطی که به اندازه کافی به یکی از k مرکز اصلی نزدیک هستند. این نقاط به آماره‌های $(N, SUM, SUMSQ)$ آن خوشه افزوده شده و خود نقطه بلافاصله از حافظه پاک می‌شود.
- **مجموعه فشرده (Compressed Set - CS):** ریزخوشه‌هایی از نقاط که به هیچ‌یک از k خوشه اصلی نزدیک نیستند، اما به یکدیگر نزدیک‌اند. این ریزخوشه‌ها نیز با آماره‌های سه‌گانه خلاصه می‌شوند.
- **مجموعه نگه‌داشته شده (Retained Set - RS):** نقاط پرت و ایزوله‌ای که نه به خوشه‌های اصلی نزدیک‌اند و نه ریزخوشه‌ای تشکیل می‌دهند. این نقاط به صورت تکی در حافظه باقی می‌مانند تا شاید با ورود داده‌های جدید به خوشه‌ای ملحق شوند.

۴.۴.۷ معیار فاصله ماهالانوبیس (Mahalanobis Distance)


برای تصمیم‌گیری درباره انتساب یک نقطه x به یک خوشه با مرکز c و انحراف معیارهای σ_i ، از فاصله ماهالانوبیس^۵ استفاده می‌شود که واریانس هر بعد را لحاظ می‌کند:

$$d_{\text{Maha}}(x, c) = \sqrt{\sum_{i=1}^d \left(\frac{x_i - c_i}{\sigma_i} \right)^2} \quad (۱۰.۷)$$

اگر فاصله ماهالانوبیس نقطه از مرکز کمتر از آستانه‌ای مشخص (معمولاً بین ۳ تا ۴ برابر انحراف معیار) باشد، نقطه به مجموعه DS تخصیص می‌یابد.

۵.۷ خوشه‌بندی اشکال دلخواه و غیرکروی: الگوریتم CURE

الگوریتم‌های K-Means و BFR فرض می‌کنند خوشه‌ها کروی یا بیضوی همگرا هستند. اما در مسائل واقعی، خوشه‌ها ممکن است اشکال هلالی، تو در تو یا غیرمحدب داشته باشند (شکل ۱.۷). الگوریتم CURE^۶ برای حل این چالش ابداع شده است.



شکل ۱.۷: نمایش نقاط نماینده و مکانیزم انقباض در الگوریتم CURE برای پوشش شکل‌های دلخواه

الگوریتم ۲.۷: الگوریتم CURE

۱. **نمونه‌گیری اولیه:** نمونه‌ای تصادفی از داده‌ها که در حافظه اصلی جا می‌شود برداشته می‌شود.
۲. **خوشه‌بندی سلسله‌مراتبی نمونه:** نمونه به کمک روش سلسله‌مراتبی خوشه‌بندی می‌شود.
۳. **انتخاب نقاط نماینده (Representative Points):** برای هر خوشه، به جای تعریف یک مرکز منفرد، c نقطه نماینده انتخاب می‌شود (نقاطی که بیشترین فاصله را از یکدیگر در درون خوشه دارند).
۴. **فشردگی و انقباض (Shrinkage):** هر نقطه نماینده به اندازه ضریب α (معمولاً $\alpha = 0.2$) به سمت مرکز ثقل خوشه کشیده می‌شود:

$$p_{\text{new}} = p + \alpha(\mu - p) \quad (11.7)$$

این انقباض اثر نقاط پرت و نویزها را به شدت خنثی می‌کند.

۵. **گذر نهایی روی کل داده‌ها:** هر نقطه داده از روی دیسک به خوشه‌ای تخصیص داده می‌شود که نزدیک‌ترین نقطه نماینده به آن را در اختیار دارد.

۶.۷ خوشه‌بندی در فضاهای غیر اقلیدسی: مفهوم شبه‌مرکز (Clustroid)

در بسیاری از مسائل کلان‌داده (نظیر گراف‌ها، فاصله‌های جاکارد یا فواصل کسینوسی)، مفهوم میانگین حسابی مختصات وجود ندارد زیرا نقاط بردار اقلیدسی نیستند. برای مدیریت این وضعیت:

تعریف ۱.۷: شبه‌مرکز (Clustroid)

در یک فضای غیر اقلیدسی، **شبه‌مرکز^a** نقطه‌ای از خود مجموعه داده است که کمترین فاصله را تا سایر نقاط خوشه دارد. بر اساس معیار بهینه‌سازی، یکی از سه تعریف زیر به کار می‌رود:

۱. نقطه‌ای که **مجموع فواصل** تا سایر نقاط خوشه را کمینه کند: $\arg \min_{c \in C} \sum_{x \in C} d(c, x)$.
۲. نقطه‌ای که **مجموع مجذور فواصل** تا سایر نقاط را کمینه کند: $\arg \min_{c \in C} \sum_{x \in C} d^2(c, x)$.
۳. نقطه‌ای که **بیشینه فاصله** تا سایر نقاط (شعاع خوشه) را کمینه کند: $\arg \min_{c \in C} \max_{x \in C} d(c, x)$.

Clustroid^a

معیارهای ارزیابی اندازه خوشه در فضای غیر اقلیدسی:

• شعاع خوشه (Cluster Radius): بیشینه فاصله یا میانگین مربعات فاصله از شبه‌مرکز:

$$R(C) = \sqrt{\frac{1}{|C|} \sum_{x \in C} d^2(x, c)} \quad (12.7)$$

• قطر خوشه (Cluster Diameter): بیشینه فاصله میان هر دو نقطه از خوشه یا جذر میانگین مربعات فواصل دوبه‌دو:

$$D(C) = \sqrt{\frac{1}{|C|(|C| - 1)} \sum_{x \in C} \sum_{y \in C, y \neq x} d^2(x, y)} \quad (13.7)$$

الگوریتم‌های خوشه‌بندی غیر اقلیدسی (نظیر الگوریتم GRGPF) در هر مرحله دو خوشه‌ای را ادغام می‌کنند که پس از ادغام، کمترین شعاع یا قطر حاصل شود.

جمع‌بندی فصل هفتم

- نفرین ابعاد موجب همگرایی تمامی فواصل دوبه‌دو در فضاهاى ابعادی بزرگ می‌گردد.
- الگوریتم K-Means++ با انتخاب احتمالاتی بر پایه مجذور فواصل، همگرایی کیفی مراکز را تضمین می‌کند.
- الگوریتم BFR داده‌های بزرگ را از طریق خلاصه آماری سه‌گانه $(N, SUM, SUMSQ)$ و معیار فاصله ماهالانوبیس خوشه‌بندی می‌نماید.
- الگوریتم CURE با تکیه بر چندین نقطه نماینده منقبض‌شده، امکان کشف خوشه‌های با اشکال پیچیده و غیرمحدب را فراهم می‌سازد.