

مبانی و الگوریتم‌های کلان‌داده

جزوه جامع درسی و مرجع دانشگاهی تحلیل کلان‌داده

بر اساس سرفصل‌ها و اسلایدهای کتاب (MMDS) Datasets Massive of Mining
تألیف: ژوره لسکوک، آناند راجارامان، جفری اولمن

گردآورنده: احسان شهبازی

مجموعه یادداشتهای آموزشی کارشناسی ارشد

۷ مهر ۱۴۰۵

فصل ۹

سامانه‌های توصیه‌گر (Recommender Systems)

۱.۹ مقدمه و پدیده دنباله طولانی

در دنیای فیزیکی، فروشگاه‌ها (نظیر کتاب‌فروشی‌ها یا سینماها) به دلیل محدودیت فضای قفسه‌ها، ناگزیرند تنها محبوب‌ترین و پرفروش‌ترین کالاها را عرضه کنند (پدیده فرهنگ عامه‌پسند یا پرفروش‌ها)^۱. اما در اقتصاد دیجیتال، وب‌سایت‌هایی مانند آمازون، نتفلیکس یا اسپاتیفای دارای هزینه‌های انبارداری و تکثیر نزدیک به صفر هستند؛ در نتیجه می‌توانند میلیون‌ها کالای خاص و کمیاب را نیز ارائه نمایند. پدیده دنباله طولانی^۲ نشان می‌دهد که اگرچه تقاضا برای هر کالای خاص موجود در انتهای دنباله اندک است، اما **مجموع تقاضای تمامی اقلام دنباله طولانی** می‌تواند از تقاضای کالاها پرفروش سنتی فراتر رود. با این حال، در میان میلیون‌ها گزینه، کاربر چگونه کالای مورد علاقه خود را پیدا کند؟ اینجاست که **سامانه‌های توصیه‌گر**^۳ به عنوان موتور محرک اقتصاد وب ظاهر می‌شوند.

۲.۹ ماتریس سودمندی (Utility Matrix)

ستون فقرات ریاضی هر سامانه توصیه‌گر، **ماتریس سودمندی**^۴ است:

تعریف ۱.۹: ماتریس سودمندی

ماتریس M با ابعاد $|U| \times |I|$ تعریف می‌شود که در آن سطرها کاربران (U)، ستون‌ها آیتم‌ها یا کالاها (I)، و درایه‌های r_{ui} بیانگر درجه علاقه یا امتیاز کاربر u به آیتم i هستند (مثلاً امتیازی بین ۱ تا ۵ ستاره).

ویژگی بارز ماتریس سودمندی در کلان‌داده، **تنک بودن فوق‌العاده**^۵ آن است: یک کاربر معمولی ممکن است از میان ده‌ها هزار فیلم موجود در نتفلیکس، تنها چند ده فیلم را تماشا کرده و امتیاز داده باشد؛ بنابراین بیش از ۹۹٪ درایه‌های ماتریس خالی (مجهول) هستند.

هدف بنیادین سامانه توصیه‌گر: پیش‌بینی دقیق مقادیر درایه‌های خالی ماتریس سودمندی و پیشنهاد آیتم‌هایی که بالاترین امتیاز تخمینی را دارند به هر کاربر.

۳.۹ روش‌های مبتنی بر محتوا (Content-Based Recommendation)

در این رویکرد، توصیه بر اساس ویژگی‌های ذاتی کالاها و تاریخچه علایق گذشته همان کاربر انجام می‌پذیرد.

۱.۳.۹ پروفایل آیتم‌ها و پروفایل کاربر

۱. **پروفایل آیتم (Item Profile):** هر کالا با یک بردار ویژگی توصیف می‌شود. برای مثال، برای یک فیلم، بردار شامل ژانرها (اکشن، کمدی)، نام کارگردان، بازیگران، و وزن کلمات کلیدی خلاصه فیلم (به کمک معیار TF-IDF) است.

^۱Blockbuster Culture^۱

^۲Long Tail^۲

^۳Recommender Systems^۳

^۴Utility Matrix^۴

^۵Extreme Sparsity^۵

۲. **پروفایل کاربر (User Profile):** سلیقه کاربر u با ترکیب بردارهای ویژگی آیت‌هایی که به آن‌ها امتیاز بالا داده است، به دست می‌آید:

$$w_u = \frac{\sum_{i \in I_u} r_{ui} \cdot x_i}{\sum_{i \in I_u} r_{ui}} \quad (1.9)$$

که در آن x_i بردار ویژگی آیت i و r_{ui} امتیاز کاربر به آن است.

۳. **تخمین امتیاز:** میزان تناسب آیت جدید j برای کاربر u با استفاده از **تشابه کسینوسی** میان بردار کاربر و بردار آیت سنجیده می‌شود:

$$\text{Score}(u, j) = \cos(w_u, x_j) = \frac{w_u \cdot x_j}{\|w_u\| \|x_j\|} \quad (2.9)$$

نکته امتحانی و کلیدی

مزایا و معایب فیلترینگ محتوا محور:

- **مزیت:** نیازی به داده‌های سایر کاربران ندارد؛ برای آیت‌های تازه اضافه شده به سیستم مشکل راه‌اندازی سرد ایجاد نمی‌کند.
- **عیب بزرگ:** **بیش‌تخصصی شدن^a** و ایجاد «حباب فیلتر»؛ سامانه هرگز کالایی خارج از دایره واژگان یا سبک گذشته کاربر را به او پیشنهاد نمی‌دهد (فقدان شانس کشف غیرمنتظره یا Serendipity).

Overspecialization^a

۴.۹ فیلترینگ مشارکتی (Collaborative Filtering)

فیلترینگ مشارکتی نیازی به استخراج محتوا و ویژگی‌های متنی آیت‌ها ندارد. در عوض، بر پایه این فرض عمل می‌کند: «افرادی که در گذشته سلیقه و امتیازدهی یکسانی داشته‌اند، در آینده نیز نظرات مشابهی خواهند داشت».

۱.۴.۹ کسینوس مرکزی (همبستگی پیرسون)

برای مقایسه دو کاربر یا دو آیت، نمی‌توان از تشابه کسینوسی معمولی استفاده کرد؛ زیرا کاربران سخت‌گیر میانگین نمراتشان پایین (مثلاً ۲ از ۵) و کاربران سهل‌گیر میانگین نمراتشان بالاست (مثلاً ۴ از ۵). راهکار علمی، استفاده از **کسینوس مرکزی^۶** یا ضریب همبستگی پیرسون است که در آن میانگین امتیازات هر کاربر از نمرات او کسر می‌شود.

مثال کاربردی ۱.۹: محاسبه کسینوس مرکزی برای دو کاربر

فرض کنید امتیاز دو کاربر A و B به چهار فیلم به شرح زیر باشد (علامت - به معنای عدم مشاهده است):

کاربر	فیلم ۱	فیلم ۲	فیلم ۳	فیلم ۴
A	۴	۵	۳	-
B	۲	۳	-	۵

میانگین امتیازات کاربر A : $\bar{r}_A = (4 + 5 + 3) / 3 = 4$. میانگین امتیازات کاربر B : $\bar{r}_B = (2 + 3 + 5) / 3 = 3.33$.
با نرمال‌سازی و کسر میانگین (تنها بر روی فیلم‌های مشترک ۱ و ۲):

$$\tilde{A} = [4 - 4, 5 - 4] = [0, 1] \quad (3.9)$$

$$\tilde{B} = [2 - 3.33, 3 - 3.33] = [-1.33, -0.33] \quad (4.9)$$

کسینوس مرکزی:

$$\text{sim}(A, B) = \frac{0 \times (-1/33) + 1 \times (-0/33)}{\sqrt{0^2 + 1^2} \sqrt{(-1/33)^2 + (-0/33)^2}} = \frac{-0/33}{1 \times 1/33} \approx -0/24 \quad (5.9)$$

(نمره منفی نشان‌دهنده اختلاف سلیقه در فیلم‌های مشترک پس از حذف اثر سخت‌گیری است).

۲.۴.۹ پیش‌بینی امتیاز کاربر به آیتم (فیلترینگ کاربر-کاربر)

برای پیش‌بینی امتیاز کاربر u به آیتم i :

۱. مجموعه N شامل k کاربر شبیه‌ترین به u را که به آیتم i امتیاز داده‌اند، انتخاب می‌کنیم.

۲. امتیاز تخمینی با میانگین‌گیری وزنی بر اساس تشابه کسینوس مرکزی به دست می‌آید:

$$\hat{r}_{ui} = \bar{r}_u + \frac{\sum_{v \in N} \text{sim}(u, v) \cdot (r_{vi} - \bar{r}_v)}{\sum_{v \in N} |\text{sim}(u, v)|} \quad (6.9)$$

۳.۴.۹ فیلترینگ آیتم-آیتم در برابر کاربر-کاربر

در عمل (به‌ویژه در آمازون)، فیلترینگ آیتم-آیتم ترجیح داده می‌شود، زیرا:

- ویژگی‌ها و ماهیت کالاها بسیار پایدارتر از سلیقه متغیر انسان‌ها در طول زمان است.
- شباهت میان آیتم‌ها را می‌توان به صورت آفلاین محاسبه و پیش‌محاسبه کرد؛ در نتیجه زمان پاسخگویی برخط بسیار سریع‌تر خواهد بود.

۵.۹ مدل‌های عامل پنهان و فاکتورسازی ماتریسی (Matrix Factorization)

پیشرفته‌ترین روش در فیلترینگ مشارکتی (که برنده جایزه یک میلیون دلاری نتفلیکس شد)، تجزیه ماتریس سودمندی به مؤلفه‌های پنهان^۷ است.

تعریف ۲.۹: تجزیه UV

فرض کنید ماتریس سودمندی تنک M دارای ابعاد $m \times n$ باشد. هدف، تقریب این ماتریس از حاصل ضرب دو ماتریس با رتبه پایین d (که $d \ll \min(m, n)$ است، مثلاً $d = 20$ یا 50) است:

$$M \approx P \cdot Q^T \quad (7.9)$$

که در آن:

• ماتریس P با ابعاد $m \times d$ بردار عوامل پنهان کاربران است (p_u) .

• ماتریس Q با ابعاد $n \times d$ بردار عوامل پنهان آیتم‌ها است (q_i) .

امتیاز تخمینی برابر است با ضرب داخلی: $\hat{r}_{ui} = p_u^T \cdot q_i$

۱.۵.۹ تابع هدف بهینه‌سازی و منظم‌سازی (Regularization)

برای جلوگیری از بیش‌برازش بر روی داده‌های محدود مشاهده‌شده، تابع هزینه به صورت مجموع مربعات خطا به همراه ترم منظم‌سازی L_2 فرمول‌بندی می‌شود:

$$\min_{P, Q} \sum_{(u, i) \in \text{Observed}} (r_{ui} - p_u^T q_i)^2 + \lambda \left(\sum_u \|p_u\|_2^2 + \sum_i \|q_i\|_2^2 \right) \quad (8.9)$$

که در آن λ ضریب منظم‌سازی است.

۲.۵.۹ بهینه‌سازی با گرادیان کاهشی تصادفی (SGD)

برای هر درایه مشاهده‌شده r_{ui} ، خطای پیش‌بینی برابر است با:

$$e_{ui} = r_{ui} - p_u^T q_i \quad (۹.۹)$$

قاعده به‌روزرسانی پارامترها با نرخ یادگیری γ :

$$p_u \leftarrow p_u + \gamma(e_{ui} \cdot q_i - \lambda p_u) \quad (۱۰.۹)$$

$$q_i \leftarrow q_i + \gamma(e_{ui} \cdot p_u - \lambda q_i) \quad (۱۱.۹)$$

این به‌روزرسانی بسیار ساده، سریع و با یک یا چند گذر روی کلان‌داده قابل اجرا است.

۳.۵.۹ مدل پایه با اثرات انحراف (Baseline Predictors)

بسیاری از تغییرات امتیازات ناشی از سلیقه نیست، بلکه ناشی از رفتارهای سیستماتیک است:

$$\hat{r}_{ui} = \mu + b_u + b_i + p_u^T q_i \quad (۱۲.۹)$$

که در آن:

- μ : میانگین کل امتیازات در سرتاسر پایگاه داده.
- b_u : انحراف کاربر u از میانگین (سخت‌گیر یا سهل‌گیر بودن).
- b_i : انحراف کیفیت آئتم i از میانگین (فیلمی فوق‌العاده یا ضعیف).

مقایسه روش‌های بهینه‌سازی SGD و ALS در آزمون

- **گرادیان کاهشی تصادفی (SGD)**: در هر گام بر روی یک جفت کاربر-آئتم عمل می‌کند. پیاده‌سازی آن بسیار ساده و همگرایی اولیه آن سریع است، اما موازی‌سازی آن به دلیل هم‌پوشانی متغیرها در خوشه‌های توزیع‌شده چالش‌برانگیز است.
- **کمترین مربعات متناوب (Alternating Least Squares - ALS)**: در هر مرحله یکی از ماتریس‌های P یا Q ثابت نگه داشته شده و مسئله به یک دستگاه معادلات خطی مجزا برای هر سطر تبدیل می‌شود. مزیت بی‌نظیر ALS در سیستم‌های توزیع‌شده این است که کاملاً به صورت موازی (Embarrassingly Parallel) بر روی خوشه‌های MapReduce یا Spark اجرا می‌گردد.

جمع‌بندی فصل نهم

- سامانه‌های توصیه‌گر با بهره‌گیری از پدیده دنباله طولانی، گزینه‌های متناسب با سلیقه فردی را پیشنهاد می‌دهند.
- فیلترینگ محتوای محور بر شباهت ویژگی‌های کالا تکیه دارد اما دچار محدودیت بیش‌تخصیصی شدن است.
- فیلترینگ مشارکتی با بهره‌گیری از کسینوس مرکزی، انحرافات مقیاسی کاربران را خنثی می‌نماید.
- مدل‌های فاکتورسازی ماتریسی (تجزیه UV) با استخراج ابعاد پنهان و بهینه‌سازی SGD بالاترین دقت پیش‌بینی را در مقیاس وسیع ارائه می‌دهند.