

مبانی و الگوریتم‌های کلان‌داده

جزوه جامع درسی و مرجع دانشگاهی تحلیل کلان‌داده

بر اساس سرفصل‌ها و اسلایدهای کتاب (MMDS) Datasets Massive of Mining
تألیف: ژوره لسکوک، آناند راجارامان، جفری اولمن

گردآورنده: احسان شهبازی

مجموعه یادداشتهای آموزشی کارشناسی ارشد

۷ مهر ۱۴۰۵

فصل ۱۱

روش‌های کاهش بعد (Dimensionality Reduction)

۱.۱۱ مقدمه و انگیزه کاهش بعد

در عصر کلان‌داده، اشیاء غالباً با بردارهای بسیار طولانی در فضاهای با ابعاد نجومی (مثلاً 10^4 تا 10^6 بعد) مدل‌سازی می‌شوند؛ مانند ماتریس اسناد در برابر واژگان در پردازش متن، یا ماتریس کاربران در برابر کالاها در وب‌سایت‌های تجارت الکترونیک.

کاهش بعد^۱ فرآیند نگاشت نقاط داده از فضای اصلی d -بعدی به فضایی با بعد بسیار کوچک‌تر $k \ll d$ است، به گونه‌ای که ساختار بنیادین، تنوع هندسی و فواصل میان نقاط داده تا حد ممکن حفظ گردد. دلایل کلیدی کاهش بعد:

۱. کاهش هزینه‌های محاسباتی و حافظه: جایگزینی محاسبات سنگین در ابعاد بالا با عملیات سریع در ابعاد فشرده.
۲. حذف نویز و افزونگی: ابعاد داده معمولاً به شدت با یکدیگر همبسته هستند؛ کاهش بعد بخش‌های نویزی و بی‌اهمیت داده را فیلتر می‌کند.
۳. استخراج معنا و مفاهیم پنهان^۲: ابعاد ترکیبی جدید اغلب مفاهیم کیفی معناداری را آشکار می‌سازند (مانند کشف سبک‌های ادبی یا ژانرهای سینمایی پنهان).
۴. امکان مصورسازی: کاهش ابعاد به ۲ یا ۳ بعد جهت رسم نمودارها و درک شهودی توسط انسان.

۲.۱۱ تجزیه مقادیر منفرد (Singular Value Decomposition - SVD)

تجزیه مقادیر منفرد (SVD) یکی از شاهکارهای جبر خطی کاربردی است که بر روی هر ماتریس مستطیلی دلخواه قابل اعمال است.

قضیه ۱.۱۱: قضیه تجزیه مقادیر منفرد

هر ماتریس حقیقی A با ابعاد $m \times n$ و رتبه r را می‌توان دقیقاً به حاصل ضرب سه ماتریس تجزیه کرد:

$$A = U \cdot \Sigma \cdot V^T \quad (1.11)$$

که در آن:

• U : ماتریس متعامد با ابعاد $m \times r$ که در شرط $U^T U = I$ صدق می‌کند. ستون‌های U ، بردارهای منفرد چپ^۳ (بردارهای ویژه ماتریس متقارن AA^T) هستند.

• Σ : ماتریس قطری با ابعاد $r \times r$ با درایه‌های مثبت بر روی قطر اصلی:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0 \quad (2.11)$$

^۱ Dimensionality Reduction
^۲ Latent Concepts

این مقادیر، **مقادیر منفرد**^b نامیده می‌شوند و برابر با جذر مقادیر ویژه ماتریس‌های $A^T A$ یا AA^T هستند. V : ماتریس متعامد با ابعاد $n \times r$ که در شرط $V^T V = I$ صدق می‌کند. ستون‌های V ، **بردارهای منفرد راست**^c (بردارهای ویژه ماتریس متقارن $A^T A$) هستند.

Left Singular Vectors^a
Singular Values^b
Right Singular Vectors^c

۱.۲.۱۱ تفسیر هندسی و فیزیکی SVD

در تحلیل داده‌ها، ماتریس A (مثلاً ماتریس کاربران در برابر فیلم‌ها) را می‌توان به صورت نگاشتی از فضای اشیاء به یک «فضای مفاهیم پنهان» تفسیر کرد:

- هر بعد در فضای پنهان متناظر با یک سطر/ستون در Σ است (مثلاً مفهوم ژانر علمی-تخیلی یا رمانس).
- سطر i -ام ماتریس U بیانگر وابستگی کاربر i به مفاهیم پنهان است.
- مقدار منفرد σ_k نشان‌دهنده «قدرت و میزان واریانس پوشش داده‌شده توسط مفهوم k -ام» است.
- سطر j -ام ماتریس V (ستون j -ام V^T) بیانگر میزان تعلق فیلم j به مفاهیم پنهان است.

۲.۲.۱۱ تقریب با رتبه پایین و قضیه اکارت-یانگ-میرسکی

اگر تنها k مقدار منفرد نخست (بزرگ‌ترین مقادیر) را نگه داریم و سایر را صفر کنیم ($k < r$):

$$A_k = U_k \cdot \Sigma_k \cdot V_k^T = \sum_{i=1}^k \sigma_i u_i v_i^T \quad (۳.۱۱)$$

قضیه ۲.۱۱: قضیه اکارت-یانگ-میرسکی (Eckart-Young-Mirsky)

ماتریس A_k ، **بهترین تقریب ممکن با رتبه k برای ماتریس A** در هر دو نرم فروبنیوس و نرم طیفی است:

$$\|A - A_k\|_F = \min_{\text{rank}(B) \leq k} \|A - B\|_F = \sqrt{\sum_{i=k+1}^r \sigma_i^2} \quad (۴.۱۱)$$

این قضیه تضمین می‌کند که خطای کاهش بعد توسط SVD حداقل ممکن در میان تمامی روش‌های خطی است. **معیار حفظ انرژی برای انتخاب رتبه بهینه k :** مجموع مجذور مقادیر منفرد ماتریس، بیانگر کل انرژی یا واریانس فروبنیوس موجود در داده‌ها است:

$$\text{Energy Total} = \|A\|_F^2 = \sum_{i=1}^r \sigma_i^2 \quad (۵.۱۱)$$

در مسائل داده‌کاوی واقعی، رتبه تقریب k معمولاً به گونه‌ای برگزیده می‌شود که حداقل ۸۰ تا ۹۰ درصد از کل انرژی داده‌ها حفظ گردد:

$$\frac{\sum_{i=1}^k \sigma_i^2}{\sum_{i=1}^r \sigma_i^2} \geq 0.90 \quad (۶.۱۱)$$

۳.۱۱ تحلیل مؤلفه‌های اصلی (Principal Component Analysis - PCA)

تحلیل مؤلفه‌های اصلی (PCA) به دنبال یافتن راستاهایی در فضا است که بیشترین پراکندگی و واریانس داده‌ها را در امتداد خود ثبت می‌کنند.

الگوریتم ۱.۱۱: مراحل اجرای PCA

۱. **مرکززدایی داده‌ها (Zero-Centering):** میانگین هر ستون را محاسبه کرده و از تمام درایه‌های آن ستون کم می‌کنیم تا میانگین هر بعد صفر شود:

$$X_{\text{centered}} = X - \mathbf{1}\mu^T \quad (۷.۱۱)$$

۲. **ماتریس کوواریانس:** ماتریس کوواریانس نمونه C را محاسبه می‌کنیم:

$$C = \frac{1}{n} X_{\text{centered}}^T X_{\text{centered}} \quad (۸.۱۱)$$

۳. **تجزیه طیفی:** مقادیر و بردارهای ویژه ماتریس کوواریانس را استخراج می‌کنیم:

$$C \cdot v_i = \lambda_i \cdot v_i \quad (۹.۱۱)$$

۴. **انتخاب مؤلفه‌های اصلی:** بردارهای ویژه $v_1, \dots, v_k$ متناظر با بزرگ‌ترین مقادیر ویژه، جهات مؤلفه‌های اصلی را مشخص می‌کنند.

رابطه شگفت‌انگیز میان PCA و SVD: اگر بر روی ماتریس مرکززدایی‌شده X_{centered} مستقیماً تجزیه SVD اعمال شود $(X_{\text{centered}} = U\Sigma V^T)$:

$$C = \frac{1}{n} (V\Sigma U^T)(U\Sigma V^T) = V \left(\frac{\Sigma^2}{n} \right) V^T \quad (۱۰.۱۱)$$

این تساوی نشان می‌دهد که **بردارهای منفرد راست V در SVD دقیقاً همان مؤلفه‌های اصلی در PCA هستند**، و واریانس در طول هر مؤلفه برابر با $\lambda_i = \sigma_i^2/n$ است! در عمل، محاسبات PCA از طریق SVD انجام می‌شود تا از تشکیل ماتریس کوواریانس سنگین اجتناب گردد.

۴.۱۱ تجزیه ماتریسی: CUR حفظ تنک بودن و تفسیرپذیری

اگرچه SVD از نظر ریاضی تقریب بهینه‌ای ارائه می‌دهد، اما در پردازش کلان‌داده با دو نقص عملیاتی بزرگ همراه است:

۱. **تخریب ساختار تنک بودن:** ماتریس اولیه A بسیار تنک است (اکثر درایه‌ها صفرند)، اما ماتریس‌های حاصل از S (U و V) کاملاً چگال (Dense) هستند که ذخیره‌سازی آن‌ها در حافظه غیرممکن است.

۲. **فقدان تفسیرپذیری فیزیکی:** سطرهای U و V ترکیبات خطی عجیبی از کلمات یا کاربران هستند؛ در حالی که متخصصان داده تمایل دارند داده‌ها را بر حسب سطرها و ستون‌های واقعی توصیف کنند.

روش **CUR^۳** برای غلبه بر این دو مشکل طراحی شد:

$$A \approx C \cdot U \cdot R \quad (۱۱.۱۱)$$

که در آن:

- C : شامل c ستون واقعی انتخاب‌شده از خود ماتریس A است.
- R : شامل r سطر واقعی انتخاب‌شده از خود ماتریس A است.
- U : یک ماتریس میانی کوچک با ابعاد $c \times r$ است که به عنوان پل میان C و R عمل می‌کند.

۱.۴.۱۱ الگوریتم انتخاب سطرها و ستون‌ها بر مبنای امتیاز اهرمی

انتخاب ستون‌ها در CUR به صورت تصادفی ساده نیست، بلکه با احتمالی متناسب با مربع نرم ستون انجام می‌شود:

الگوریتم ۲.۱۱: انتخاب ستون‌ها و سطرها در تجزیه CUR

۱. به ازای هر ستون j از ماتریس A ، احتمال انتخاب را متناسب با انرژی فروبنیوس آن ستون تعریف می‌کنیم:

$$p_j = \frac{\sum_i A_{ij}^2}{\|A\|_F^2} \quad (۱۲.۱۱)$$

۲. تعداد c ستون را با جایگذاری بر اساس توزیع احتمال p_j انتخاب کرده و در ماتریس C قرار می‌دهیم.

۳. برای جلوگیری از اریبی آماری، هر ستون انتخاب‌شده j در ماتریس C بر ضریب $\sqrt{c \cdot p_j}$ تقسیم می‌شود.

۴. به طور کاملاً متقارن، r سطر از A با احتمالات متناسب با انرژی سطر انتخاب شده و در ماتریس R قرار می‌گیرند و بر $\sqrt{r \cdot p_i}$ تقسیم می‌شوند.

۵. **محاسبه ماتریس میانی U :** فرض کنید ماتریس W با ابعاد $c \times r$ اشتراک سطرها و ستون‌های انتخاب‌شده در ماتریس اصلی باشد. ماتریس U برابر با شبه‌وارون مور-پنروز ماتریس W تعریف می‌شود:

$$U = W^+ \quad (۱۳.۱۱)$$

۵.۱۱ تصویرسازی‌های تصادفی و لم جانسون-لیندن اشتراوس (JL Lemma)

اگر مجموعه‌ای از n نقطه در یک فضای بی‌نهایت با بعد بالا $\mathbb{R}^d$ داشته باشیم، آیا می‌توان بدون از دست دادن فواصل میان نقاط، بعد فضا را کاهش داد؟

قضیه ۳.۱۱: لم جانسون-لیندن اشتراوس (Johnson-Lindenstrauss Lemma)

برای هر مجموعه شامل n نقطه در فضای اقلیدسی $\mathbb{R}^d$ و هر خطای مجاز $0 < \epsilon < 1$ ، یک نگاشت خطی تصادفی $f: \mathbb{R}^d \rightarrow \mathbb{R}^k$ وجود دارد، به گونه‌ای که با بعد هدف:

$$k = O\left(\frac{\log n}{\epsilon^2}\right) \quad (۱۴.۱۱)$$

فواصل اقلیدسی میان تمامی جفت‌نقاط با تقریب $1 \pm \epsilon$ حفظ می‌شود:

$$(1 - \epsilon)\|x - y\|^2 \leq \|f(x) - f(y)\|^2 \leq (1 + \epsilon)\|x - y\|^2 \quad \forall x, y \in X \quad (۱۵.۱۱)$$

نکته امتحانی و کلیدی

نکته اعجاب‌انگیز لم JL که پای ثابت سؤالات امتحانی است: بعد هدف k هیچ ارتباطی با بعد اولیه d ندارد! چه داده‌ها در فضای ۱۰۰ بعدی باشند و چه در فضای یک میلیون بعدی، اگر $n = 10^4$ نقطه داشته باشیم و خطای ۱۰٪ بخواهیم، نگاشت به فضایی با حدود چند صد بعد، تمامی فواصل را تضمین‌شده حفظ می‌کند. ماتریس تصویرسازی تصادفی به سادگی با کشیدن درایه‌ها از یک توزیع نرمال استاندارد گاوسی $\mathcal{N}(0, 1)$ یا متغیرهای برنولی متعادل (± 1) تولید می‌شود.

جمع‌بندی فصل یازدهم

- کاهش بعد راهکاری اساسی برای غلبه بر نفرین ابعاد و کشف ساختارهای پنهان در کلان‌داده است.
- قضیه SVD هر ماتریس را به مقادیر منفرد تجزیه کرده و طبق قضیه اکارت-یانگ بهترین تقریب با رتبه پایین را ارائه می‌دهد.
- الگوریتم PCA از طریق مؤلفه‌های اصلی، واریانس بیشینه داده‌های نرمال‌شده را استخراج می‌کند.

- تجزیه CUR با برگزیدن سطرها و ستون‌های واقعی، تنک بودن و تفسیرپذیری را حفظ می‌نماید.
- لم جانسون-لیندن اشتراوس اثبات می‌کند که تصویرسازی تصادفی به ابعادی از مرتبه $O(\frac{\log n}{\epsilon^2})$ ، کلیه فواصل اقلیدسی را مستقل از بعد اولیه مصون نگه می‌دارد.